Ιόνιο Πανεπιστήμιο

Τμήμα Πληροφορικής



- Πτυχιακή εργασία -

- Μελέτη και ανάπτυξη εκπαιδευτικού συστήματος με διαφορική ιδιωτικότητα -

Σταμάτης Πέτρου inf2021186

Επιβλέπων: Χριστόφορος Νταντογιάν

8 Ιουλίου 2025

Επιβλέπων

Χριστόφορος Νταντογιάν, Αναπληρωτής Καθηγητής

Ιόνιο Πανεπιστήμιο – Τμήμα Πληροφορικής

Τριμελής Επιτροπή

Εμμανουήλ Μαγκος, Καθηγητής

Ιόνιο Πανεπιστήμιο – Τμήμα Πληροφορικής

Αγγελική Τσώχου, Αναπληρώτρια Καθηγήτρια

Ιόνιο Πανεπιστήμιο – Τμήμα Πληροφορικής

Υπεύθυνη δήλωση: Βεβαιώνω ότι είμαι ο συγγραφέας της παρούσας πτυχιακής εργασίας. Οποιαδήποτε βοήθεια που έλαβα λειτούργησε ως οδηγός για την ορθή συγκέντρωση των απαιτήσεων και την εκπόνηση της εργασίας. Επισημαίνω ότι οι πηγές που χρησιμοποίησα για τα δεδομένα είναι ακριβώς αναφερόμενες ή παραφρασμένες όπου απαιτείται. Τέλος, η προετοιμασία της πτυχιακής εργασίας πραγματοποιήθηκε προσωπικά από εμένα σε συνεργασία με τον επιβλέποντα καθηγητή, ειδικά για τις απαιτήσεις του προγράμματος σπουδών του Τμήματος Πληροφορικής του Ιονίου Πανεπιστημίου.

Declaration of Responsibility: I certify that I am the author of this thesis. Any assistance I received served as a guide for the proper gathering of requirements and the execution of the project. I note that the sources I used for the data are precisely referenced or paraphrased where necessary. Finally, the preparation of this thesis was carried out personally by me in collaboration with my supervising professor, specifically for the requirements of the curriculum of the Department of Informatics at the Ionian University.

ΠΕΡΙΛΗΨΗ

Η διαφορική ιδιωτικότητα (Differential Privacy, DP) έχει καθιερωθεί ως ένα de-facto πρότυπο για την προστασία προσωπικών δεδομένων, προσφέροντας μαθηματικά τεκμηριωμένες εγγυήσεις απορρήτου ακόμη και σε περιβάλλοντα με πολύπλοκη επεξεργασία και ανάλυση πληροφορίας. Στη σύγχρονη εποχή, όπου η ασφάλεια και η ιδιωτικότητα αποτελούν αναπόσπαστο κομμάτι της καθημερινότητας τόσο σε προσωπικό όσο και σε επιχειρησιακό επίπεδο, η ανάγκη για συστήματα που ενσωματώνουν από τη σχεδίασή τους μηχανισμούς προστασίας δεδομένων είναι πιο επιτακτική από ποτέ. Στο πλαίσιο αυτό, η παρούσα πτυχιακή εργασία ασχολείται με τη μελέτη και την υλοποίηση τεχνικών διαφορικής ιδιωτικότητας, εστιάζοντας στη δημιουργία ενός υποσυστήματος που μπορεί να ενσωματωθεί σε πληροφοριακές πλατφόρμες για τη διασφάλιση της ιδιωτικότητας χρηστών.

Η εργασία βασίζεται στη χρήση του συνόλου δεδομένων EdNet, το οποίο περιλαμβάνει εκατομμύρια αλληλεπιδράσεις μαθητών σε εκπαιδευτικό περιβάλλον. Μέσα από την προσεκτική συλλογή, ανάλυση και προεπεξεργασία αυτών των δεδομένων, μελετήθηκαν τα χαρακτηριστικά τους και εντοπίστηκαν οι ευαίσθητες πληροφορίες που χρειάζονται προστασία. Στη συνέχεια, σχεδιάστηκε και υλοποιήθηκε ένας μηχανισμός διαφορικής ιδιωτικότητας σε offline περιβάλλον ικανός να τροποποιεί τα δεδομένα με στοχευμένο θόρυβο ώστε να επιτυγχάνεται υψηλό επίπεδο ιδιωτικότητας χωρίς να υποβαθμίζεται η χρησιμότητά τους.

Το τελικό αποτέλεσμα είναι ένα ολοκληρωμένο πλαίσιο επεξεργασίας και προστασίας δεδομένων το οποίο αξιολογήθηκε μέσω πειραμάτων για διαφορετικές τιμές της παραμέτρου ιδιωτικότητας ϵ. Τέλος, τα αποτελέσματα επιβεβαιώνουν ότι η διαφορική ιδιωτικότητα μπορεί να εφαρμοστεί με πρακτική επιτυχία σε εκπαιδευτικά δεδομένα μεγάλης κλίμακας, προσφέροντας μια ισορροπία ανάμεσα στην προστασία των προσωπικών πληροφοριών και στη δυνατότητα αξιοποίησης των δεδομένων για ανάλυση, έρευνα και βελτίωση εκπαιδευτικών συστημάτων.

ABSTRACT

Differential Privacy (DP) has become a de-facto standard for the protection of personal data, offering mathematically documented privacy guarantees even in the context of advanced information processing and analysis. In the modern era, where security and privacy are an inherent component of everyday life on both individual and business levels, the need for systems that incorporate mechanisms for the protection of data by design is more paramount than ever. In this context, this thesis focuses on the research and application of differential privacy techniques, with the priority of building a subsystem that can be applied to information platforms for offering user privacy.

The work is based on the use of the EdNet dataset comprising millions of student interactions in an educational environment. Through meticulous collection, analysis and pre-processing of these data, their features were studied and sensitive information needing protection was identified. Later, a differential privacy mechanism was constructed and implemented in an offline environment with the capability of altering data through targeted noise, in order to achieve a high level of privacy without compromising its utility.

The result is a combined data protection and processing system, which was experimentally tested for different values of the privacy parameter ϵ. The results ultimately confirm that differential privacy can be applied with practical utility to large-scale educational data offering a trade-off between the protection of personal data and the ability to use the data for analysis, research and educational system improvement.

ΕΥΧΑΡΙΣΤΙΕΣ

Θα ήθελα να ευχαριστήσω τον καθηγητή μου, κύριο Χριστόφορο Νταντογιάν, αναπληρωτή καθηγητή του Τμήματος Πληροφορικής του Ιονίου Πανεπιστημίου, για τη στήριξη και την καθοδήγησή του κατά την εκπόνηση της πτυχιακής μου εργασίας, αλλά και για την ουσιαστική συμβολή του στο να γνωρίσω τον κόσμο της κυβερνοασφάλειας. Ευχαριστώ επίσης την οικογένειά μου για τη διαρκή τους στήριξη, ηθική και πρακτική, σε κάθε βήμα της πορείας μου. Τέλος, ευχαριστώ τους καθηγητές που με επηρέασαν θετικά, καθώς και τους φίλους μου, παλιούς και νέους, που στάθηκαν δίπλα μου όλα αυτά τα χρόνια.

Κέρκυρα, Ιούλιος 2025

Σταμάτης Πέτρου

Πίνακας Περιεχομένων

ΠΕΡΙΛΗΨΗ 4

ABSTRACT 5

ΕΥΧΑΡΙΣΤΙΕΣ 6

ΚΕΦΑΛΑΙΟ Α: Εισαγωγή 9

ΚΕΦΑΛΑΙΟ Β: Θεωρητικό Υπόβαθρο 10

Β.1: Διαφορική Ιδιωτικότητα 10

Β.2 Σχετικές εργασίες με την εφαρμογή του Differential Privacy 13

Β.2.1 Privacy preserved Parking 13

Β.2.2 NITRO: an Interconnected 5G-IoT Cyber Range 14

Β.2.3 Google (RAPPOR – Chrome & Android Telemetry) 14

Β.3: Ανάλυση Μάθησης και Εξόρυξη Εκπαιδευτικών Δεδομένων 15

Β.4: Global & Local Διαφορική ιδιωτικότητα και η διάκριση Interactive vs Non-Interactive 16

Β.4.1 Global και Local Differential Privacy 17

Β.4.1.1 Αλληλεπιδραστική (Interactive) και Μη Αλληλεπιδραστική (Non-Interactive) Διαφορική Ιδιωτικότητα 19

Β.5: Διαδραστικά Εκπαιδευτικά Συστήματα (IES) 21

Β.6 GDPR και Διαφορική Ιδιωτικότητα 23

ΚΕΦΑΛΑΙΟ Γ: Παρουσίαση του συνόλου δεδομένων EdNet 25

Γ.1 Περιγραφή Υποσυνόλων (KT1–KT4) και Ανάλυση Δεδομένων και Μεταβλητών 26

Γ.2 Ευαίσθητες Πληροφορίες και Μοτίβα 27

ΚΕΦΑΛΑΙΟ Δ: Σχεδιασμός & Υλοποίηση Προστασίας με Differential Privacy 28

Δ.1: Επιλογή Μοντέλου Προστασίας 29

Δ.2: Εφαρμογή DP σε Patterns και Aggregates 30

Δ.3: Χρήση Interactive Προσέγγισης 33

Δ.4 Ανάλυση αποτελεσμάτων 36

ΚΕΦΑΛΑΙΟ Ε: Γενικά Συμπεράσματα και Προσωπική Γνώμη 38
Ε.1 Μεθοδολογία Αξιολόγησης 39
Ε.2 Συμπεράσματα από τα αποτελέσματα 40
Ε.3 Περιορισμοί 40
Ε.4 Μελλοντική Εργασία 41
ΠΑΡΑΡΤΗΜΑ 42
Π.1 Αναλυτικοί Πίνακες Μετρικών 43
Π.2 Ρυθμίσεις και Logs 44
Π.3 Εικόνες 46
Γλωσσάρι Ξενικών Όρων 50

ΚΕΦΑΛΑΙΟ Α: Εισαγωγή

Για περισσότερο από μία δεκαετία, η διαφορική ιδιωτικότητα στέκεται ως ο οδηγός στην εξερεύνηση και την εδραίωση μεθόδων προστασίας προσωπικών δεδομένων. Οι μαθηματικές της ρίζες επιτρέπουν στους ερευνητές να διαμορφώνουν ένα κοινό υπόβαθρο σκέψης σε πολλούς τομείς, από την υγεία έως και την εκπαίδευση, οδηγώντας σε εφαρμογές με δομημένη ασφάλεια και απορρήτου. Η ουσία δεν είναι η απόκρυψη αλλά μια δομική ενίσχυση του απορρήτου, ανεξάρτητα από τον επιτιθέμενο ή την τεχνολογία. Η διαφορική ιδιωτικότητα στηρίζεται στο θεμέλιο ότι η παρουσία ή η απουσία ενός μεμονωμένου χρήστη δεν αλλάζει ουσιαστικά τα αποτελέσματα (Dwork et al., 2006). Αυτό επιτυγχάνεται μέσω σταθερής επένδυσης θορύβου στο αποτέλεσμα, έτσι ώστε οι παρατηρήσεις να παραμένουν πολύ κοντά για οποιοδήποτε μεμονωμένο δεδομένο στο σύνολο δεδομένων (Wikipedia, 2025). Στη σύγχρονη εποχή της Τεχνητής Νοημοσύνης και της Βαθιάς Μάθησης, η διαφορική ιδιωτικότητα είναι κρίσιμα χρήσιμη. Βοηθά να διατηρείται η ισορροπία της χρηστικότητας και ασφάλειας, όταν οι αλγόριθμοι μαθαίνουν από εκατομμύρια διεπαφές. Ερευνητικά εργαλεία όπως η IBM Diffprivlib, αποδεικνύουν την πρακτική δυνατότητα εφαρμογής Differential Privacy (DP) σε analytics και machine learning (Holohan et al., 2019).

Στον ιδιωτικό τομέα, εταιρείες όπως η Apple εφαρμόζουν Differential Privacy ώστε τα δεδομένα να υποβάλλονται με θόρυβο πριν φύγουν από τη συσκευή του χρήστη διασφαλίζοντας ότι δεν μπορούν να ανακατασκευαστούν απομονωμένα στοιχεία (Apple, 2017). Ωστόσο, η βέλτιστη τιμή του epsilon παραμένει κρίσιμο θέμα (π.χ. κριτική για την ελάχιστη προστασία που δίνει το iOS με τιμές $\epsilon > 6$) (Greenberg, 2017).

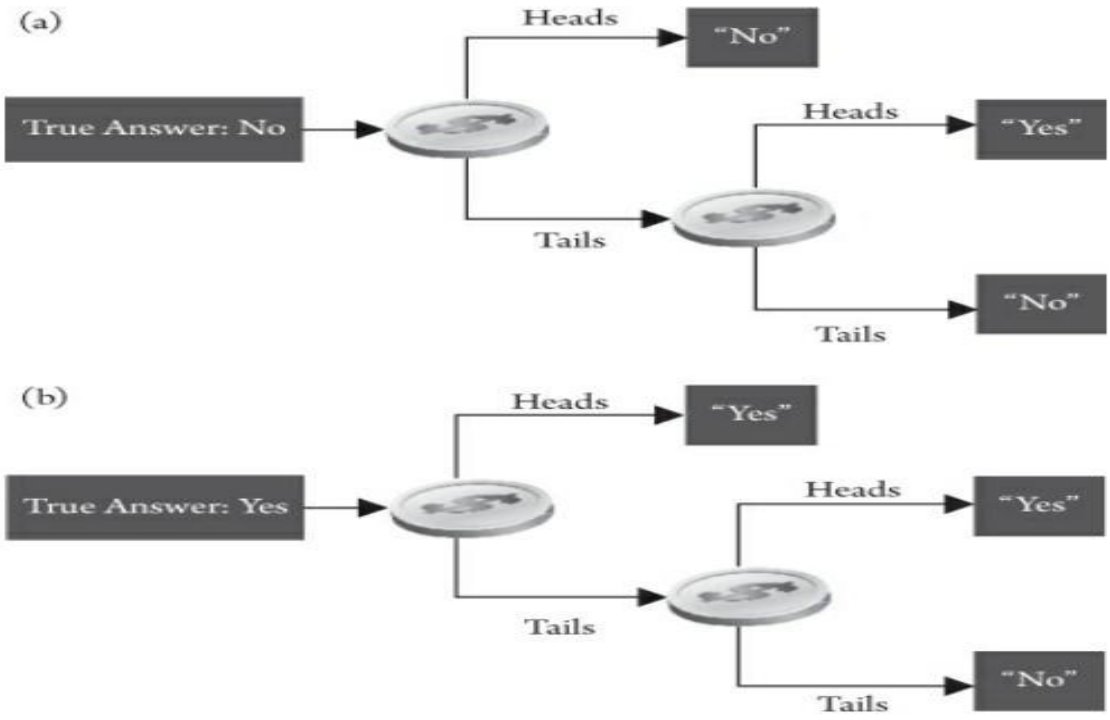
Στην εργασία αυτή, εστιάζεται στο πώς η διαφορική ιδιωτικότητα μπορεί να ενισχύσει την ανάλυση συμπεριφοράς (learning analytics) μέσα στο περιβάλλον των Έξυπνων Εκπαιδευτικών Συστημάτων (IES). Θα μελετηθεί πώς ένα σύστημα όπως το EdNet αποκαλύπτει μοτίβα μαθητών (π.χ. source vs score, erase/undo sequences) και πώς αυτά μπορούν να προστατευτούν με interactive DP, προσθέτοντας θόρυβο πριν τη συσσώρευση ώστε να διασφαλίζεται η ιδιωτικότητα χωρίς να χάνεται η ουσία της ανάλυσης.

ΚΕΦΑΛΑΙΟ Β: Θεωρητικό Υπόβαθρο

Β.1: Διαφορική Ιδιωτικότητα

Η Διαφορική Ιδιωτικότητα (Differential Privacy) είναι μια μέθοδος που επιτρέπει τη συλλογή και ανάλυση δεδομένων χωρίς να αποκαλύπτονται πληροφορίες που αφορούν κάποιο συγκεκριμένο άτομο. Όπως εξηγεί το MIT σε άρθρο του, ένα απλό παράδειγμα είναι η ερώτηση προς φοιτητές: «Έχετε αντιγράψει ποτέ σε εξετάσεις;». Πριν απαντήσουν στο ερώτημα, ρίχνουν ένα κέρμα. Αν το κέρμα τύχει κορώνα, απαντούν ειλικρινά. Αν τύχει γράμματα, ρίχνουν ξανά: αν τύχει κορώνα στην επόμενη ρίψη, λένε "ναι", αλλιώς "όχι".

Το φαινόμενο αυτό προσθέτει αβεβαιότητα στην ατομική απάντηση αλλά επιτρέπει την εξαγωγή στατιστικά χρήσιμων αποτελεσμάτων στο σύνολο των δεδομένων προστατεύοντας την ιδιωτικότητα του κάθε φοιτητή. Η παρακάτω εικόνα δείχνει την απλούστερη υλοποίηση της διαφορικής ιδιωτικότητας:



Εικόνα 1: Αναπαράσταση ρίψη κέρματος με την διαφορική ιδιωτικότητα

Η διαφορική ιδιωτικότητα προσφέρει έναν μαθηματικά θεμελιωμένο τρόπο προστασίας της ατομικής πληροφορίας μέσα σε ένα σύνολο δεδομένων. Εξασφαλίζει, δηλαδή, πως η συμμετοχή ή μη ενός ατόμου σε ένα dataset δεν επηρεάζει σημαντικά τα τελικά αποτελέσματα οποιουδήποτε υπολογισμού πάνω σε αυτό.

Δύο παράμετροι είναι κρίσιμες για την ισχύ της προστασίας: το ϵ (epsilon) και το δ (delta):

Η παράμετρος ϵ εκφράζει πόσο ιδιωτικά δεδομένα είναι τα δεδομένα προς ανάλυση. Δηλαδή, το πόσο μπορούν να αλλάξουν οι πιθανότητες εμφάνισης ενός αποτελέσματος όταν ένα άτομο προστεθεί ή αφαιρεθεί από τα δεδομένα. Όσο μικρότερο είναι το ϵ, δηλαδή να τείνει προς στις τιμές του 0, τόσο λιγότερη πληροφορία διαρρέει και τόσο πιο ισχυρή είναι η προστασία. Το αντίθετο συμβαίνει όταν η παράμετρος ϵ δέχεται τιμές μεγαλύτερες του 1 με αποτέλεσμα η ιδιωτικότητα των δεδομένων να γίνεται λιγότερο ισχυρή.

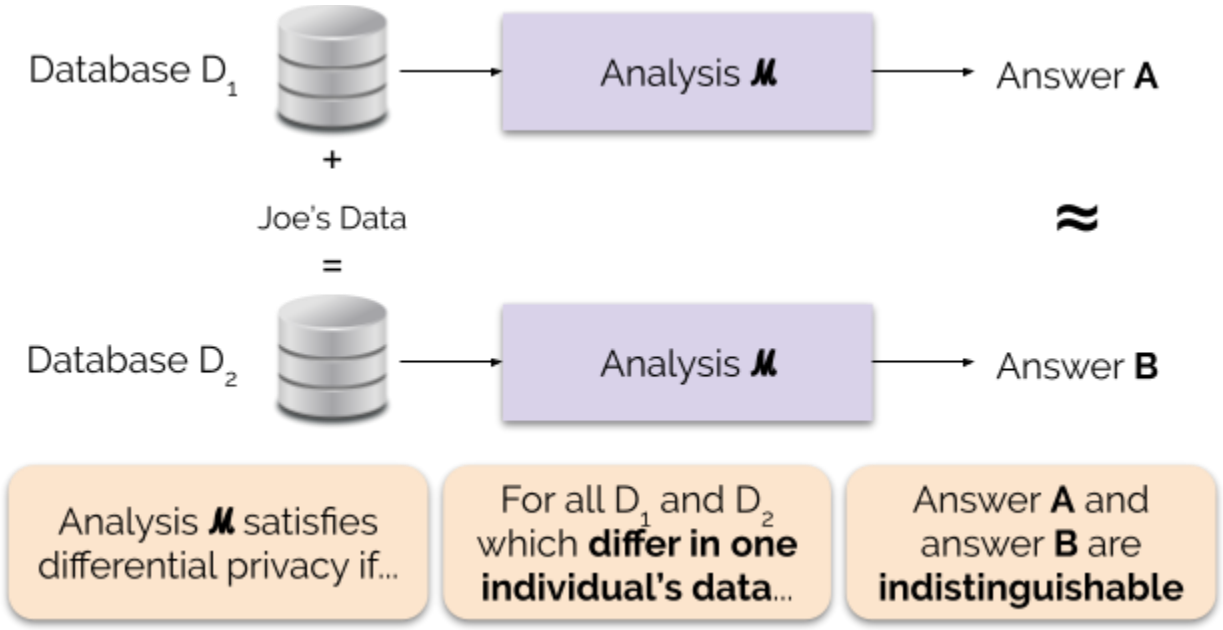
Η παράμετρος δ από την άλλη, εκφράζει την πιθανότητα να αποτύχει αυτή η εγγύηση, να υπάρξει δηλαδή ένα σενάριο όπου το ϵ δεν τηρείται. Με άλλα λόγια, η παράμετρος δ δείχνει μια μικρή πιθανότητα παραβίασης της προστασίας που δίνει το ϵ. Πρόκειται για μια μικρή τιμή ανοχής, συνήθως πολύ κοντά στο μηδέν (π.χ. 10^{-6} ή 10^{-8}), που επιτρέπει σπανιότατες εξαιρέσεις στον κανόνα.

Εξετάζοντας τους όρους της διαφορικής ιδιωτικότητας με μαθηματική προσέγγιση, ένας μηχανισμός M λέμε ότι ικανοποιεί (ϵ, δ)-διαφορική ιδιωτικότητα αν για κάθε ζευγάρι γειτονικών συνόλων δεδομένων D_1 και D_2 και για κάθε σύνολο δυνατών αποτελεσμάτων S, ισχύει η εξής ανισότητα:

$$P[M(D_1) \in S] \leq e^{\epsilon} \cdot P[M(D_2) \in S] + \delta$$

Με άλλα λόγια, η όλη φιλοσοφία της διαφορικής ιδιωτικότητας βασίζεται στο εξής: ακόμη κι αν κάποιος είχε πρόσβαση στα αποτελέσματα μιας ανάλυσης δεν θα μπορούσε με αξιοπιστία να καταλάβει αν ένα συγκεκριμένο άτομο συμμετείχε ή όχι. Το άτομο, τελικά, παραμένει κρυμμένο μέσα στο σύνολο.

Στη παρακάτω εικόνα φαίνεται ο τρόπος λειτουργίας της:



Εικόνα 2: Τρόπος λειτουργίας του Differential Privacy. Έχοντας 2 σύνολα δεδομένων και η μια έχει τα δεδομένα του Joe, το αποτέλεσμα της ανάλυσης θα είναι ακριβώς το ίδιο

Η αρχή της διαφορικής ιδιωτικότητας αποτυπώνεται καθαρά στο παραπάνω διάγραμμα: δύο σύνολα δεδομένων τα οποία διαφέρουν μόνο σε μία εγγραφή και υποβάλλονται στον ίδιο μηχανισμό. Παρά την ύπαρξη αυτής της μικρής διαφοράς, τα αποτελέσματα που προκύπτουν είναι στατικά παρόμοια χάρη στον προστιθέμενο θόρυβο. Αυτό σημαίνει ότι η συμμετοχή ή μη ενός ατόμου δεν επηρεάζει ουσιαστικά την τελική έξοδο προστατεύοντας έτσι την ιδιωτικότητά του. Με άλλα λόγια, το σύστημα θολώνει την ατομική πληροφορία αλλά διατηρεί τη χρησιμότητα των συνολικών στατιστικών.

B.2 Σχετικές εργασίες με την εφαρμογή του Differential Privacy

Η διαφορική ιδιωτικότητα έχει αποτελέσει αντικείμενο εκτεταμένων ερευνών και εφαρμογών σε πολλούς τομείς, από πλατφόρμες εκπαιδευτικού περιεχομένου και ενσωμάτωσή της σε λογισμικά όπως το iOS της Apple, μέχρι και πειραματισμούς για την ανάπτυξη καινοτόμων παρεμετρωποιήσεων των ίδιων μηχανισμών της. Παράλληλα, η έννοια της διαφορικής ιδιωτικότητας στην προστασία δεδομένων προσωπικού χαρακτήρα αναδεικνύεται ως μια από τις σημαντικότερες προσεγγίσεις στο χώρο του data privacy. Πρόκειται για έναν μηχανισμό που υιοθετείται συνεχώς από οργανισμούς και συμβάλλει στην καθιέρωσή του στις αρχιτεκτονικές προστασίας.

B.2.1 Privacy preserved Parking

Παράδειγμα στην εφαρμογή της διαφορικής ιδιωτικότητας εντοπίζεται στο σύστημα έξυπνων πάρκινγκ σε περιβάλλοντα 5G. Σύμφωνα με την έρευνα των Khaliq, Anjum, Ajmal, Webber, Mehbodniya, Khan, που έγινε δημοσίευσή της το 2022, το σύστημα συλλέγει δεδομένα σχετικά με την τοποθεσία οχημάτων, τη διάρκεια στάθμευσης και τις πινακίδες, τα οποία είναι ιδιαίτερα ευαίσθητα. Με άλλα λόγια, τα συλλεγόμενα δεδομένα βοηθούν το σύστημα να προτείνει θέσεις πάρκινγκ στα οχήματα των χρηστών ανάλογα με την κίνηση, την τοποθεσία που θέλουν να παρκάρουν και το μέγεθος του αυτοκινήτου. Σκοπός της έρευνας αυτής είναι ο πειραματισμός σε νέες ιδέες ώστε να αποφεύγεται το μποτιλιάρισμα των αυτοκινήτων, και κυρίως, η άμεση εξυπηρέτηση στους χρήστες σύμφωνα με τις ανάγκες τους. Ωστόσο, η απουσία των μηχανισμών προστασίας θα μπορούσε να οδηγήσει σε παραβίαση της ιδιωτικότητας των χρηστών και την εύκολη ταυτοποίηση των ατόμων. Για τον λόγο αυτό, η προσέγγιση που προτάθηκε στην έρευνα αυτή είναι να εφαρμόζει Local Differential Privacy, δηλαδή τη προσθήκη ελεγχόμενου θορύβου στα δεδομένα πριν από τη διαμοίρασή τους έτσι ώστε να διασφαλιστεί η ιδιωτικότητα των χρηστών χωρίς οι πάροχοι να μπορούν να αναύλουν τα δεδομένα (π.χ. εκτίμηση διαθεσιμότητας θέσεων στάθμευσης). Η έρευνα αυτή, μάλιστα, αναδεικνύει τη δυνατότητα της εφαρμογής της LDP σε real-time και δυναμικά περιβάλλοντα, όπως οι έξυπνες πόλεις, και καταδεικνύει τον τρόπο με τον οποίο η προστασία ιδιωτικότητας μπορεί να συνυπάρξει με την αξιοπιστία και την ακρίβεια των υπηρεσιών.

B.2.2 NITRO: an Interconnected 5G-IoT Cyber Range

Το NITRO Project είναι ένα νέο και σύγχρονο ευρωπαϊκό ερευνητικό έργο, το οποίο επικεντρώνεται συην εκπαίδευση χρηστών στον τομέα της κυβερνοασφάλειας, με έμφαση στις τεχνολογίες 5G και Internet Of Things (IoT).

Σκοπός της έρευνας αυτής είναι η ανάπτυξη μιας εκπαιδευτική πλατφόρμας όπου οι χρήστες θα έχουν πρόσβαση και θα μπορούν να μελετούν τα καινοτόμα ‘‘δωμάτια’’ που παρέχουν σύγχρονο υλικό. Η πλατφόρμα του NITRO παρέχει πολλαπλά περιβάλλοντα προσομοίωσης στρατηγικών επίθεσης και άμυνας, ενισχύοντας τις δεξιότητες των χρηστών. Μερικές από τις δραστηριότητες που περιλαμβάνονται στο project είναι ή κατάκτηση της σημαίας (capture the flag) και η επίθεση σε μοντέλα τεχνητής νοημοσύνης. Πιο ειδικά, μια από τις βασικές πτυχές του έργου είναι η εφαρμογή του Differential Privacy για την προστασία των δεδομένων των χρηστών κατά τη διάρκεια των δραστηριοτήτων τους. Τελικά, η προσέγγιση αυτή διασφαλίζει ότι τα προσωπικά δεδομένα των χρηστών παραμένουν ανώνυμα, επιτρέποντας την αξιολόγησή τους στα courses χωρίς να θίγεται η ιδιωτικότητά τους.

B.2.3 Google (RAPPOR – Chrome & Android Telemetry)

Η Google εφαρμόζει Differential Privacy μέσω του συστήματος RAPPOR (Randomized Aggregatable Privacy-Preserving Ordinal Response) σε προϊόντα όπως το Chrome και το Android, με στόχο τη συλλογή ανωνυμοποιημένων δεδομένων χρήσης. Το σύστημα καταγράφει στοιχεία όπως οι επεκτάσεις που χρησιμοποιούνται, οι ενεργές ρυθμίσεις και τα μοτίβα περιήγησης, χωρίς να συνδέει τα δεδομένα με συγκεκριμένους χρήστες. Μέσω Local Differential Privacy, κάθε χρήστης προσθέτει θόρυβο στα δεδομένα πριν αυτά σταλούν στους servers της Google, εξασφαλίζοντας την ανωνυμία των χρηστών. Με αυτόν τον τρόπο η Google μπορεί να εξάγει στατιστικά μοτίβα χρήσης, να εντοπίζει προβλήματα ή σφάλματα και να βελτιώνει τις εφαρμογές της χωρίς να παραβιάζεται η ιδιωτικότητα των χρηστών αποτελώντας ένα χαρακτηριστικό παράδειγμα εφαρμογής Differential Privacy σε παγκόσμιας κλίμακας προϊόντα.

B.3: Ανάλυση Μάθησης και Εξόρυξη Εκπαιδευτικών Δεδομένων

Η αναδυόμενη χρήση των δεδομένων που συλλέγονται από εκπαιδευτικά περιβάλλοντα όπως πλατφόρμες e-learning, συστήματα tutoring, και εργαλεία διαχείρισης μάθησης, έχει δώσει ώθηση στον κλάδο της ανάλυσης μάθησης (learning analytics) και της εξόρυξης εκπαιδευτικών δεδομένων (educational data mining, EDM). Οι τεχνικές αυτές στοχεύουν στη βελτίωση της εμπειρίας του μαθητή μέσω της ανακάλυψης προτύπων και πληροφοριών από τα δεδομένα που παράγονται κατά τη μαθησιακή διαδικασία.

Ωστόσο, η μαζική συλλογή δεδομένων από τις εκπαιδευτικές αλληλεπιδράσεις εγκυμονεί σοβαρούς κινδύνους για την ιδιωτικότητα των μαθητών. Οι απλές τεχνικές ανωνυμοποίησης έχουν επανειλημμένως αποδειχθεί ανεπαρκείς καθώς σε πολλές περιπτώσεις επιτρέπει την επαναταυτοποίηση χρηστών με βάση τα μοτίβα συμπεριφοράς τους (Narayanan & Shmatikov, 2008). Ειδικά στον εκπαιδευτικό τομέα, όπου τα δεδομένα περιέχουν πληροφορίες για επιδόσεις, προτιμήσεις και γνωστικά μοτίβα, η προστασία της ιδιωτικότητας πρέπει να είναι προτεραιότητα.

Η Διαφορική Ιδιωτικότητα προσφέρει μια ισχυρή λύση, καθιερώνοντας μαθηματικές εγγυήσεις για τη διατήρηση της ιδιωτικότητας κατά την ανάλυση δεδομένων. Με τη χρήση τεχνικών όπως η προσθήκη ελεγχόμενου θορύβου στις απαντήσεις ερωτημάτων ή στα aggregations (συγκεντρωτικές τιμές που συνδιάζουν πολλά ατομικά δεδομένα), παρέχεται η δυνατότητα να εξαχθούν χρήσιμα στατιστικά χωρίς να εκτεθούν οι επιμέρους συνεισφορές των χρηστών. Συγκεκριμένα, σε περιβάλλοντα μάθησης, η εφαρμογή Differential Privacy μπορεί να επιτρέψει την εξαγωγή δεικτών προόδου, τη μοντελοποίηση συμπεριφορών ή την προσωποποιημένη ανατροφοδότηση, ενώ παράλληλα διασφαλίζεται πως τα ατομικά δεδομένα κάθε μαθητή παραμένουν εμπιστευτικά. Έρευνες όπως των Dwork & Roth (2014), Bindschaedler et al. (2022) και το πρακτικό framework Opacus του Meta (2020) δείχνουν τον δρόμο για εφαρμογές που ενισχύουν την ιδιωτικότητα χωρίς να υποβαθμίζουν την αξία της ανάλυσης. Η προσαρμογή των τεχνικών αυτών στα χαρακτηριστικά των διαδραστικών εκπαιδευτικών συστημάτων αποτελεί πρόκληση. Η φύση των δεδομένων είναι συχνά αλληλεπιδραστική, χρονικά εξαρτώμενη και εξαιρετικά λεπτομερώς κατανεμημένη. Αυτό απαιτεί τη σχεδίαση και υλοποίηση προηγμένων μεθόδων προστασίας, όπως Local Differential Privacy, όπου ο θόρυβος εισάγεται στον χρήστη πριν την αποστολή των δεδομένων στον server. Έτσι, ακόμη και αν ο server δεχτεί επίθεση, η αποκάλυψη ευαίσθητων μοτίβων παραμένει πρακτικά ανέφικτη.

Συνολικά, η Ανάλυση Μάθησης σε συνδυασμό με την εφαρμογή τεχνικών Διαφορικής Ιδιωτικότητας μπορεί να προσφέρει μια ισορροπία ανάμεσα στη βελτίωση της εκπαίδευσης και τη διασφάλιση της ιδιωτικότητας, αρκεί να σχεδιαστεί με θεμελιώδη σεβασμό προς τον μαθητή ως φορέα ευαίσθητων δεδομένων.

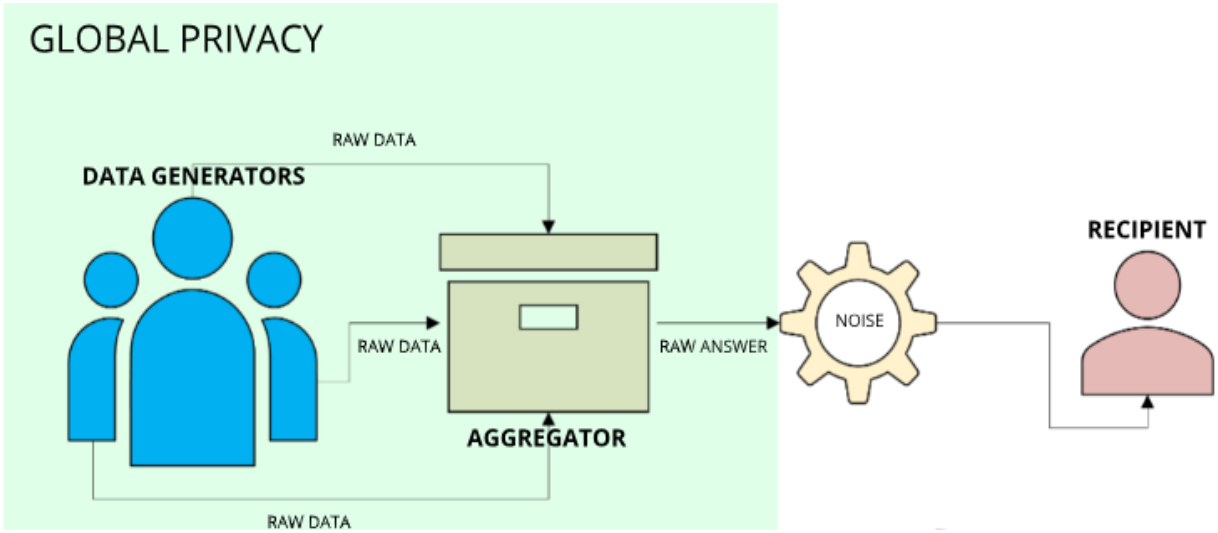
B.4: Global & Local Διαφορική ιδιωτικότητα και η διάκριση Interactive vs Non-Interactive

Η Διαφορική Ιδιωτικότητα έχει αναδειχθεί ως μία από τις πιο ισχυρές προσεγγίσεις για την προστασία ευαίσθητων προσωπικών δεδομένων. Στο πλαίσιο αυτής της μεθοδολογίας, έχουν διαμορφωθεί δύο κρίσιμες διακρίσεις που επηρεάζουν σημαντικά τον τρόπο εφαρμογής της: η πρώτη αφορά στο ποιος προσθέτει τον θόρυβο (Global vs Local Differential Privacy), ενώ η δεύτερη σχετίζεται με τον τρόπο με τον οποίο εκτελούνται τα ερωτήματα στα δεδομένα (Interactive vs Non-Interactive Differential Privacy). Οι δύο αυτές διακρίσεις αποτελούν θεμέλιο για τον σχεδιασμό ασφαλών συστημάτων που αξιοποιούν προσωπικά δεδομένα με τρόπο που διασφαλίζει την ιδιωτικότητα των χρηστών.

B.4.1 Global και Local Differential Privacy

Η Global Differential Privacy (ή αλλιώς Central DP) βασίζεται στην ύπαρξη ενός κεντρικού επιμελητή δεδομένων (curator), ενός φορέα ή server ο οποίος συλλέγει τα αρχικά (raw) δεδομένα και προσθέτει τον απαραίτητο θόρυβο μόνο κατά τη φάση της δημοσιοποίησης αποτελεσμάτων ή απαντήσεων σε ερωτήματα. Το μοντέλο αυτό θεωρείται ιδανικό όταν ο curator είναι αξιόπιστος και μπορεί να διαχειρίζεται με ασφάλεια τα δεδομένα καθώς παρέχει υψηλότερη ακρίβεια για δεδομένο επίπεδο ιδιωτικότητας ϵ, λόγω του ελέγχου που έχει στον μηχανισμό θορυβοποίησης (Desfontaines, 2020). Το αρνητικό του μοντέλου αυτού είναι η ανάγκη για πλήρη εμπιστοσύνη στον κεντρικό curator καθώς συλλέγει τα πραγματικά δεδομένα των χρηστών με αποτέλεσμα να δημιουργείται ένα σημείο κεντρικής ευπάθειας.

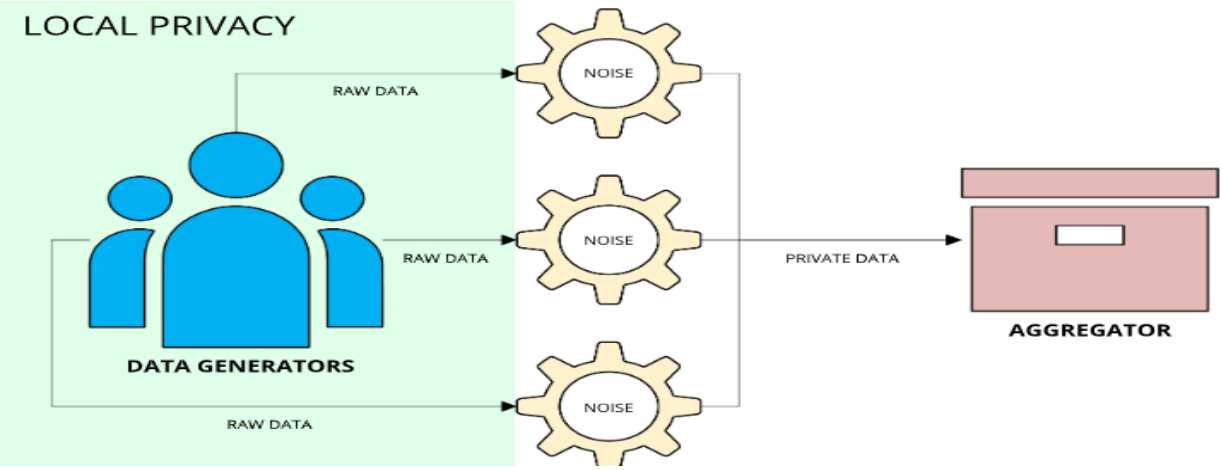
Στο παρακάτω σχήμα φαίνεται αναλυτικά η υλοποίησή του:



Εικόνα 3: Τρόπος λειτουργίας του Global (Central) Differential Privacy

Στον αντίποδα, στο Local Differential Privacy (LDP), ο θόρυβος προστίθεται από τον ίδιο τον χρήστη πριν τα δεδομένα σταλούν σε οποιονδήποτε εξωτερικό αποδέκτη. Αυτό σημαίνει πως κανένας εξωτερικός φορέας δεν έχει ποτέ πρόσβαση στα αρχικά δεδομένα, γεγονός που ενισχύει δραστικά την προστασία της ιδιωτικότητας. Το LDP είναι ιδιαίτερα χρήσιμο σε περιπτώσεις όπου δεν μπορεί να τεθεί εμπιστοσύνη σε έναν κεντρικό curator, όπως στην περίπτωση κατανεμημένων εφαρμογών ή συλλογής δεδομένων από προσωπικές συσκευές (Erlingsson et al., 2014). Το μειονέκτημα του μοντέλου αυτού είναι η υψηλότερη θορυβοποίηση η οποία απαιτεί μεγαλύτερο πλήθος δειγμάτων για να εξαχθούν αξιόπιστα στατιστικά συμπεράσματα (Kairouz et al., 2016).

Στο παρακάτω σχήμα φαίνεται ο τρόπος λειτουργίας του:

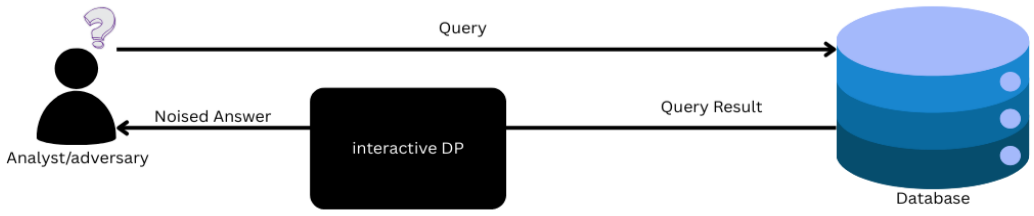


Εικόνα 4: Τρόπος λειτουργίας του Local Differential Privacy

B.4.1.1 Αλληλεπιδραστική (Interactive) και Μη Αλληλεπιδραστική (Non-Interactive) Διαφορική Ιδιωτικότητα

Η δεύτερη σημαντική διάκριση αφορά στον τρόπο πρόσβασης στα δεδομένα:

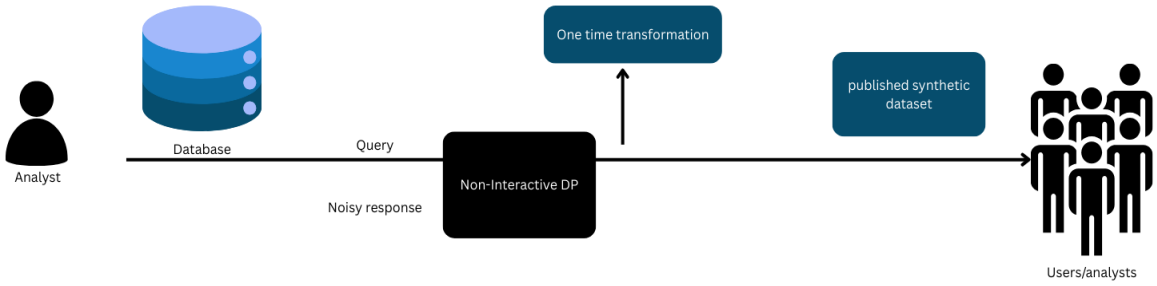
Στην Αλληλεπιδραστική Διαφορική Ιδιωτικότητα (interactive DP), ο αναλυτής έχει τη δυνατότητα να εκτελεί διαδοχικά ερωτήματα σε έναν μηχανισμό που διαχειρίζεται τα δεδομένα με διαφορική ιδιωτικότητα. Κάθε ερώτημα απαντάται με κάποιο βαθμό ακρίβειας αλλά καταναλώνει τμήμα του συνολικού "budget" ιδιωτικότητας ϵ, το οποίο πρέπει να παρακολουθείται με ακρίβεια. Για παράδειγμα, ένας χρήστης κάνει ερώτηση σε μια βάση δεδομένων και το σύστημα του επιστρέφει την απάντηση με θόρυβο. Το μοντέλο αυτό προσφέρει ευελιξία και προσαρμοστικότητα αλλά εγκυμονεί τον κίνδυνο σταδιακής διαρροής ευαίσθητης πληροφορίας μέσω της σύνθεσης πολλών ερωτημάτων (Dwork & Roth, 2014). Στο παρακάτω σχήμα φαίνεται αναλυτικότερα η χρήση του:



Εικόνα 5: Χρήση της Interactive DP: ο χρήστης κάνει ερώτηση στατιστικών στη Βάση Δεδομένων του συστήματος και επιστρέφεται θορυβώδης απάντηση

Αντίθετα, στην Μη Αλληλεπιδραστική Διαφορική Ιδιωτικότητα (Non-Interactive DP), δημιουργείται εκ των προτέρων ένα θορυβοποιημένο σύνολο δεδομένων (ή στατιστικών) το οποίο δημοσιοποιείται μία φορά. Από εκεί και πέρα, κανένα νέο ερώτημα δεν επιτρέπεται προς το αρχικό dataset. Αυτή η προσέγγιση είναι ιδανική για περιπτώσεις όπου απαιτείται η διάθεση δεδομένων προς τρίτους χωρίς να τίθεται σε κίνδυνο η ιδιωτικότητα· για παράδειγμα, στη δημοσιοποίηση στατιστικών παιδείας, δημόσιας υγείας ή

χρήσης μιας πλατφόρμας (Machanavajjhala et al., 2008). Στο παρακάτω σχήμα φαίνεται πιο αναλυτικά η χρήστη της Non-Interactive έκδοσης:



Ένα χαρακτηριστικό παράδειγμα χρήσης των παραπάνω μοντέλων είναι στην εκπαιδευτική ανάλυση δεδομένων. Αν χρειάζεται δυναμική προσαρμογή της εμπειρίας του μαθητή βάσει της αλληλεπίδρασής του με ένα εκπαιδευτικό εργαλείο τότε επιλέγεται συνήθως Interactive DP ώστε να απαντώνται ζωντανά ερωτήματα, όπως ο χρόνος μελέτης ή η επίδοση σε τεστ. Αντιθέτως, εάν ο στόχος είναι η δημοσίευση συγκεντρωτικών στατιστικών απόδοσης τάξεων ή ομάδων μαθητών τότε εφαρμόζεται Non-Interactive DP ώστε να διατεθεί το απαραίτητο υλικό χωρίς περαιτέρω πρόσβαση σε ευαίσθητα δεδομένα.

Η επιλογή μεταξύ Global και Local DP, αλλά και μεταξύ Interactive και Non-Interactive μοντέλων, πρέπει να καθορίζεται από το επίπεδο εμπιστοσύνης, τον όγκο και τη φύση των δεδομένων, καθώς και τις λειτουργικές απαιτήσεις του συστήματος. Στα περιβάλλοντα που έχουν υψηλές απαιτήσεις προστασίας (π.χ όπως η εκπαίδευση ή η υγεία) η συνδυαστική χρήση των παραπάνω τεχνικών είναι συχνά απαραίτητη για να διασφαλιστεί η ισορροπία μεταξύ ιδιωτικότητας και χρηστικότητας.

B.5: Διαδραστικά Εκπαιδευτικά Συστήματα (IES)

Στη σύγχρονη ψηφιακή εποχή, η εκπαίδευση έχει αρχίσει να μετασχηματίζεται ριζικά. Η απλή παρουσίαση περιεχομένου στον υπολογιστή αρχίζει και εξαλείφεται. Πλέον οι διαδραστικές μέθοδοι μάθησης, προσαρμοσμένες στις ανάγκες κάθε μαθητή παίζουν καθοριστικό ρόλο. Σε αυτό το πλαίσιο, τα Διαδραστικά Εκπαιδευτικά Συστήματα (Interactive Educational Systems - IES) είναι αναγκαία.

Πρόκειται για πλατφόρμες ή εφαρμογές που «αντιδρούν» στις ενέργειες του χρήστη με στόχο να προσαρμόσουν τη μαθησιακή διαδικασία ανάλογα με την απόδοσή του. Για παράδειγμα, ένας μαθητής που δυσκολεύεται σε κάποιο κεφάλαιο μπορεί να λάβει περισσότερη καθοδήγηση, ασκήσεις επανάληψης ή εναλλακτικούς τρόπους παρουσίασης του περιεχομένου. Αυτά τα συστήματα βασίζονται σε συνεχή συλλογή δεδομένων από τη συμπεριφορά του χρήστη, όπως χρόνος απάντησης, σωστές/λάθος επιλογές, ακόμα και η διαδρομή που ακολουθεί μέσα στο εκπαιδευτικό υλικό. Παραδείγματα αυτών είναι η πλατφόρμα του Duolingo για εξάσκηση σε ξένες γλώσσες.

Πέραν του παραδείγματος, μερικές κατηγορίες που ανήκουν στον ευρύτερο χώρο των IES είναι:

- Intelligent Tutoring Systems (ITS): όπου το σύστημα λειτουργεί σαν προσωπικός «ψηφιακός δάσκαλος».
- Adaptive Learning Platforms: που τροποποιούν αυτόματα το επίπεδο δυσκολίας.
- Games και gamified περιβάλλοντα, όπου η εκπαίδευση γίνεται μέσα από παιχνίδι και προκλήσεις.

Το βασικό χαρακτηριστικό τους είναι πως η αλληλεπίδραση είναι συνεχής και κάθε ενέργεια του μαθητή καταγράφεται, όχι απαραίτητα με κακή πρόθεση, αλλά για να προσφέρει πιο ποιοτική εμπειρία. Ωστόσο, αυτή η συνεχής καταγραφή και η συσσώρευση λεπτομερών δεδομένων (π.χ. πόσα δευτερόλεπτα κοίταξε μια σελίδα, αν ξαναείδε ένα quiz, πόσο συχνά κάνει λάθη σε συγκεκριμένο τύπο ασκήσεων) δημιουργεί σοβαρά ερωτήματα για την ιδιωτικότητα.

Στην πράξη, η εκπαίδευση γίνεται ένα σύνθετο σύστημα παρακολούθησης της σκέψης και τα δεδομένα αυτά, όσο χρήσιμα κι αν είναι για αναλύσεις, μπορούν να εκθέσουν το προφίλ του μαθητή με τρόπους που ούτε μπορεί να φανταστεί κανείς. Ειδικά αν συνδυαστούν με τεχνητή νοημοσύνη ή ψυχομετρικά μοντέλα, τότε είναι δυνατό να εξαχθούν πολύ προσωπικά συμπεράσματα για τον χρήστη.

Στο σημείο αυτό έρχεται η ανάγκη για ισχυρή προστασία απορρήτου. Είναι αναγκαίο να χρησιμοποιηθούν οι μαθηματικά θεμελιωμένες μεθόδους προστασίας, όπως η Διαφορική Ιδιωτικότητα, που να εγγυώνται ότι δεν μπορεί να είναι γνωστό αν κάποιος συμμετείχε ή όχι στο σύστημα μόνο από τα δεδομένα που

συλλέχθηκαν. Και αυτό είναι κρίσιμο, ειδικά σε πλατφόρμες με πολλούς μαθητές, επαναλαμβανόμενες αλληλεπιδράσεις και χρήση για στατιστική ή βελτιστοποίηση της διδασκαλίας.

Καθώς τα εκπαιδευτικά περιβάλλοντα γίνονται ολοένα και πιο «έξυπνα» με τη χρήση της τεχνητής νοημοσύνης, των φωνητικών διεπαφών, ακόμα και την ανάλυση συναισθημάτων, είναι σημαντικό η προστασία των προσωπικών δεδομένων να μην είναι απλώς μια σκέψη εκ των υστέρων, αλλά να ενσωματώνεται στον σχεδιασμό εξαρχής (privacy by design). Στο πλαίσιο αυτό, έργα όπως αυτά του Υπουργείου Παιδείας και Θρησκευμάτων (ΥΠΑΙΘ) αξιοποιούν προσωπικούς ψηφιακούς βοηθούς για τους μαθητές προωθώντας τη δημιουργία «έξυπνων» εκπαιδευτικών συστημάτων (Experience AI).

B.6 GDPR και Διαφορική Ιδιωτικότητα

Ο Γενικός Κανονισμός για την Προστασία Δεδομένων (ΓΚΠΔ-GDPR) αποτελεί το θεμέλιο της ευρωπαϊκής νομοθεσίας για την προστασία της ιδιωτικότητας, εισάγοντας από το 2018 ένα αυστηρό και ενοποιημένο πλαίσιο για όλα τα κράτη-μέλη. Στόχος του είναι η ενίσχυση της προστασίας των προσωπικών δεδομένων και η ενδυνάμωση των δικαιωμάτων των πολιτών απέναντι στις αυξανόμενες πρακτικές συλλογής και ανάλυσης πληροφοριών. Στο επίκεντρο του Κανονισμού βρίσκονται οι αρχές επεξεργασίας, η ασφάλεια των δεδομένων και η έννοια της «προστασίας εξ ορισμού» οι οποίες αποτυπώνονται μέσα από συγκεκριμένα άρθρα και αιτιολογικές σκέψεις.

Σύμφωνα με το Άρθρο 5 του ΓΚΠΔ, η επεξεργασία προσωπικών δεδομένων πρέπει να διέπεται από θεμελιώδεις αρχές, όπως η νομιμότητα, η διαφάνεια, ο περιορισμός του σκοπού, η ελαχιστοποίηση των δεδομένων, η ακρίβεια, ο περιορισμός της περιόδου αποθήκευσης, η ακεραιότητα και η εμπιστευτικότητα. Οι υπεύθυνοι επεξεργασίας έχουν επιπλέον την υποχρέωση λογοδοσίας, δηλαδή να μπορούν να αποδεικνύουν τη συμμόρφωσή τους με τις παραπάνω αρχές. Η Διαφορική Ιδιωτικότητα έρχεται να στηρίξει κυρίως την ελαχιστοποίηση των δεδομένων και την προστασία της εμπιστευτικότητας καθώς η τεχνική της προσθήκης θορύβου περιορίζει τη δυνατότητα ταυτοποίησης μεμονωμένων ατόμων διατηρώντας ταυτόχρονα την αξία των δεδομένων για ανάλυση.

Ειδικότερα, το Άρθρο 25 εισάγει την έννοια της προστασίας δεδομένων εξ ορισμού (privacy by design & by default), η οποία αποτελεί κύριο συστατικό του ΓΚΠΔ. Η Διαφορική ιδιωτικότητα εντάσσεται ιδανικά σε αυτήν την απαίτηση καθώς σχεδιάζεται εξαρχής ώστε να διασφαλίζει την ιδιωτικότητα. Ένα σύστημα που υλοποιεί DP μπορεί να αποδείξει ότι ενσωματώνει προστασία ήδη από το στάδιο της ανάπτυξης, κάτι που συνεπάγεται άμεσα με το άρθρο 25.

Επιπρόσθετα, το Άρθρο 32 αφορά την ασφάλεια της επεξεργασίας και επιβάλλει στους υπευθύνους επεξεργασίας και στους εκτελούντες να εφαρμόζουν κατάλληλα τεχνικά και οργανωτικά μέτρα για την προστασία των δεδομένων. Στο άρθρο αυτό, αναφέρονται παραδείγματα όπως η ψευδωνυμοποίηση και η κρυπτογράφηση. Στην περίπτωση της Διαφορικής Ιδιωτικότητας, αν και δεν είναι επίσημη η αναφορά στον τρόπο λειτουργίας της, μπορεί να θεωρηθεί συμπληρωματικό μέτρο που ενισχύει την ασφάλεια. Ειδικότερα, σε περιβάλλοντα όπου τα δεδομένα πρέπει να παραμένουν διαθέσιμα για ανάλυση (π.χ. εκπαιδευτικά, ιατρικά ή εμπορικά δεδομένα), η DP προσφέρει έναν τρόπο να διατηρηθεί η χρησιμότητα χωρίς να διακυβεύεται η ανωνυμία.

Επίσης, τα «συμφραζόμενα» είναι οι καταληκτικές σκέψεις και αποφάσεις του Κανονισμού πριν τη συγγραφή των άρθρων. Το συμφραζόμενο 26 τονίζει ότι δεδομένα που έχουν ανωνυμοποιηθεί με τρόπο ώστε να μην είναι πλέον δυνατή η ταυτοποίηση του ατόμου, δεν θεωρούνται προσωπικά δεδομένα. Η

πρόκληση στην πράξη είναι ότι πολλές παραδοσιακές τεχνικές ανωνυμοποίησης (π.χ. η απλή αφαίρεση ονομάτων) έχουν αποδειχθεί ανεπαρκείς καθώς είναι ευάλωτες σε στρατηγικά πολύπλοκες επιθέσεις. Η Διαφορική Ιδιωτικότητα προσφέρει μαθηματικά ένα τεκμηριομένο πλαίσιο για να φανεί περισσότερο αυτήν την ιδέα της «πραγματικής ανωνυμοποίησης».

Αντίστοιχα, το συμφραζόμενο 78 αναφέρεται ρητά στην ανάγκη τεχνικών και οργανωτικών μέτρων για την εφαρμογή της αρχής του privacy by design. Εδώ η DP παρουσιάζεται ως ένα σύγχρονο εργαλείο που επιτρέπει στους υπεύθυνους επεξεργασίας να αποδείξουν ότι ενσωματώνουν την προστασία της ιδιωτικότητας στο ίδιο το σύστημα και όχι απλώς σε επίπεδο πολιτικής.

Συνολικά, η Διαφορική Ιδιωτικότητα μπορεί να θεωρηθεί ως ένα πρακτικό και αποτελεσματικό μέσο συμμόρφωσης με τον ΓΚΠΔ. Ενισχύει τις αρχές του άρθρου 5, υλοποιεί στην πράξη το άρθρο 25, ενδυναμώνει την ασφάλεια που απαιτεί το άρθρο 32 και δίνει συγκεκριμένη απάντηση στα συμφραζόμενα 26 και 78. Μέσω αυτής, οι οργανισμοί μπορούν να επιτύχουν μια ισορροπία ανάμεσα στην αξιοποίηση των δεδομένων και στη διασφάλιση της ιδιωτικότητας, μειώνοντας σημαντικά τον κίνδυνο παραβίασης και ενισχύοντας τη λογοδοσία τους.

ΚΕΦΑΛΑΙΟ Γ: Παρουσίαση του συνόλου δεδομένων EdNet

Στην παρούσα εργασία, θα αναλυθεί εις βάθους αρχικά το σύνολο δεδομένων που χρειάστηκε για την ανάπτυξη του συστήματος με διαφορική ιδιωτικότητα. Αρχικά το σύνολο δεδομένων βρέθηκε από την ιστοσελίδα αποθετηρίου κώδικα GitHub.

Για να γίνει πιο αξιόπιστη η έρευνα, χρησιμοποιήθηκε το σύνολο δεδομένων EdNet, ένα έργο που είναι από τις μεγαλύτερες συλλογές διαδραστικών μαθησιακών δεδομένων. Πιο συγκεκριμένα, το EdNet σχεδιάστηκε από την εταιρία Santa με καταγωγή την Νότια Κορέα που σκοπός της είναι η βελτιστοποίηση της εξατομικευμένης μάθησης των μαθητών που προετοιμάζονται για τις αγγλικές εξετάσεις TOEIC. Το σημαντικό είναι ότι το EdNet μελετά τη συμπεριφορά των μαθητών μέσα από χρονικές αλληλεπιδράσεις περιλαμβάνοντας πληροφορίες όπως ποια ερώτηση απαντήθηκε ή αν είναι σωστή ή λάθος. Ένα θετικό στοιχείο που έχει το EdNet, μέσω της πλατφόρμας του GitHub, είναι πως διατίθεται στο ευρύ κοινό για χρήση (open source). Η μελέτη του EdNet είναι απαιτητική καθώς πρέπει να γίνουν κατανοητά τα χαρακτηριστικά των μαθησιακών μοτίβων και επίσης η αναγνώριση των ευαίσθητων πληροφοριών που ενδέχεται να διαρρέυσουν. Τέλος, διερευνούνται τα μοτίβα που μπορούν να αξιοποιηθούν κακόβουλα θέτοντας σε κίνδυνο τους μαθητές.

Γ.1 Περιγραφή Υποσυνόλων (KT1–KT4) και Ανάλυση Δεδομένων και Μεταβλητών

Το EdNet αποτελείται αρχικά από τέσσερα διακριτά υποσύνολα δεδομένων KT1, KT2, KT3, KT4 τα οποία συνδέονται μεταξύ τους. Κάθε υποσύνολο το EdNet εστιάζει σε διαφορετικό επίπεδο ανάλυσης της μαθησιακής δραστηριότητας προσφέροντας μιας είδους κλιμακώμενης πληροφόρησης. Πιο αναλυτικά:

KT1 (Knowledge Tracing): Το KT1 αποτελεί το αρχικό αλλά και κύριο σύνολο αφού αποτελείται με πάνω από 131 εκατομμύρια αλληλεπιδράσεις από πάνω από 780 χιλιάδες μαθητές. Τα κύρια χαρακτηριστικά του υποσυνόλου που είναι καταγεγραμμένα είναι το ID του μαθητή, το ID της ερώτησης, αν απάντησε σωστά ή λάθος και μια χρονοσφραγίδα (timestamp) της αλληλεπίδρασης με το σύστημα (web ή mobile). Το KT1 είναι η βάση της ανάλυσης των επιδόσεων αλλά και της μοντελοποίησης της μάθησης

KT2 (Question Metadata): Το υποσύνολο του KT2 περιλαμβάνει χρήσιμες, και επιπρόσθετες, πληροφορίες για τις ερωτήσεις. Για παράδειγμα, υπάρχουν ακόλουθα στάδια δράσης (actions) όπως το enter, respond, submit, κάνοντας έτσι πιο εύκολη στη χαρτογράφηση την αλληλεπίδραση και την διαδικασία της απάντησης. Με αυτόν τον τρόπο, είναι δυνατή η παρακολούθηση όχι μόνο του τελικού αποτελέσματος αλλά και του πώς έφτασε ο μαθητής σε αυτό.

KT3 (Lecture Interaction Data): Το υποσύνολο του KT3 γίνεται ακόμη πιο εμπλουτισμένο καθώς η πληροφορία είναι πιο ακριβής και επεξηγηματική. Τα δεδομένα που εμπεριέχονται στο υποσύνολο είναι συλλογή από εκπαιδευτικά βίντεο και θεωρητικό υλικό. Επιπρόσθετα, περιλαμβάνει ενέργειες όπως pause, resume, skip, και το timestamp για κάθε βίντεο. Το KT3 ανοίγει τη δυνατότητα για συνδυαστική ανάλυση μεταξύ θεωρίας και πράξης, γεγονός σημαντικό για την εξατομίκευση της μάθησης.

KT4 (Tag Metadata): Το KT4 αποτελεί το πιο λεπτομερές υποσύνολο, καταγράφοντας κάθε δυνατή ενέργεια του χρήστη στην πλατφόρμα, όπως ενέργειες purchase, cancel, audio play/pause, choice κ.ά. Παρέχει το πλήρες φάσμα συμπεριφορικών δεδομένων, τα οποία, αν και πολύτιμα για μοντελοποίηση της μαθησιακής συμπεριφοράς, εγείρουν και σοβαρές ανησυχίες ως προς την προστασία της ιδιωτικότητας.

Γ.2 Ευαίσθητες Πληροφορίες και Μοτίβα

Μέσα από την εφαρμογή του EdNet ρέουν σημαντικές πληροφορίες των χρηστών. Κατά τη διάρκεια μιας εξάσκησης ενός μαθητή/τριας σε ένα τεστ ή σε ένα μέρος ενός τεστ (π.χ reading, listening ή και video lectures) ασκούν ενέργειες στο σύστημα με αποτέλεσμα την απάντησή τους στις ερωτήσεις του διαγωνίσματος. Όμως, η επιλογή του μαθητή σε συγκεκριμένη ερώτηση ως απάντηση καταγράφεται. Το σύστημα αποθηκεύει την ενέργεια αυτή και παράγει ένα «μοτίβο» κινήσεων των μαθητών ξεχωριστά και υπάρχει καταγεγραμμένο σε αρχείο. Τα μοτίβα των μαθητών είναι πληροφορία που αναλύει το σύστημα του EdNet της Santa και μπορεί να δώσει αυτοματοποιημένες προτιμήσεις σε κάθε μαθητή ώστε, σε περίπτωση λάθους απάντησης, το σύστημα να μπορεί να αναγνωρίσει το λάθος και να προτείνει παρόμοια μέρη του τεστ ώστε ο μαθητής να αναπτύξει τις ικανότητες του στα μέρη που δεν μπορεί να αποδώσει.

Αυτό το γεγονός όμως “στοιχήζει” καθώς ένας επιτιθέμενος μπορεί να κάνει capture τα logs των μαθητών και να αναλύσει τα μοτίβα συμπεριφορών τους και να βγάλει συμπεράσματα για το που υστερούν και πόσο. Με άλλα λόγια, είναι απαραίτητο να υπάρχει ιδιωτικότητα στα δεδομένα που ρέουν εντός του συστήματος επειδή υπάρχει η περίπτωση παρακολούθησης. Βάσει αυτού, ένας επιτιθέμενος μπορεί να διαβάσει τις αδυναμίες των μαθητών και να επεκτείνει την επίθεσή του, πράγμα που δεν θα αναλυθεί στην παρούσα πτυχιακή εργασία. Εστιάζοντας στις αδυναμίες στα αποθηκευμένα μοτίβα των μαθητών, που είναι οι καταγεγραμμένες ενέργειες στη διάρκεια του τεστ, οι ευαίσθητες πληροφορίες μπορεί να είναι: το ονοματεπώνυμο του μαθητή, το συγκεκριμένο id που έχει αποθηκευτεί στο σύστημα ο κάθε μαθητής, το email του ή του γονέα, πατρώνυμο και μητρόνυμο, αριθμός τηλεφώνου, συσκευή, η διεύθυνση ip από την οποία ο μαθητής είναι ενεργός στο πληροφοριακό σύστημα κ.α. Αυτές οι πληροφορίες, χάρην στην ιδιωτικότητα του συγκεκριμένου project και σύνολο δεδομένων έχουν αποκρυφθεί. Στην παρούσα εργασία, έχοντας ερευνήσει με λεπτομέρεια το σύνολο δεδομένων, η διαφορική ιδιωτικότητα θα εφαρμοστεί στα υπάρχοντα δεδομένα. Η ανάλυση γίνεται για να αποκρυφθούν ακόμα περισσότερο οι πραγματικές πληροφορίες. Απότερος σκοπός της ανάλυσης είναι η επιτυχία της ανάπτυξης ενός συστήματος με διαφορική ιδιωτικότητα που θα διασφαλίζει ότι τα προσωπικά δεδομένα των χρηστών παραμένουν εμπιστευτικά ακόμη και κατά την εξαγωγή χρήσιμων συμπερασμάτων.

ΚΕΦΑΛΑΙΟ Δ: Σχεδιασμός & Υλοποίηση Προστασίας με Differential Privacy

Το παρόν κεφάλαιο αποτελεί την πρακτική υλοποίηση της προστασίας της ιδιωτικότητας για το σύνολο δεδομένων EdNet με βάση τις αρχές της Διαφορικής Ιδιωτικότητας. Στη παρούσα εργασία θεωρήθηκε σκόπιμο να εφαρμοστεί η μέθοδος της Τοπικής DP (LDP) όπου ο θόρυβος προστίθεται απευθείας σε κάθε εγγραφή πριν από οποιαδήποτε αποστολή δεδομένων. Μέσω των μηχανισμών Laplace και Randomized Response, προστατεύονται ευαίσθητες συνεχείς και δυαδικές μεταβλητές αντίστοιχα, όπως ο χρόνος απόκρισης και η ορθότητα της απάντησης. Σκοπός είναι η δημιουργία ενός προστατευμένου αντίγραφου των δεδομένων που να διατηρεί τη στατιστική τους χρησιμότητα για ανάλυση και μηχανική μάθηση, γεγονός που αξιολογείται συστηματικά μέσω πειραμάτων που μετρούν την επίδραση διαφόρων επιπέδων θορύβου (παράμετρος ϵ) στην ακρίβεια ενός μοντέλου πρόβλεψης.

Δ.1: Επιλογή Μοντέλου Προστασίας

Η επιλογή του μοντέλου προστασίας είναι κατά κύριο λόγο υποκειμενικό φαινόμενο και αυτό οφείλεται στο γεγονός της κάλυψης των αναγκών του κάθε ατόμου. Στη συγκεκριμένη εργασία, έχει επιλεχθεί ο σχεδιασμός και η υλοποίηση να πραγματοποιηθεί με τοπική διαφορική ιδιωτικότητα (Local Differential Privacy) σε συνδυασμό με αλληλεπιδραστικό σενάριο (Interactive Differential Privacy). Στο μοντέλο του LDP, η εισαγωγή θορύβου εισάγεται από την πλευρά του χρήστη πριν τα δεδομένα μεταφερθούν στον εξυπηρετητή (server). Με αυτόν τον τρόπο, ακόμη και ο πάροχος της υπηρεσίας δεν έχει πρόσβαση στα raw δεδομένα. Η επιλογή αυτή βασίστηκε σε δύο παραμέτρους:

1. Έλλειψη εμπιστοσύνης στον εξυπηρετητή: Στο συγκεκριμένο περιβάλλον, ο συλλέκτης των δεδομένων δεν πρέπει να μπορεί να τα αναλύσει σε ακατέργαστη μορφή, ώστε να αποτραπεί οποιοδήποτε ενδεχόμενο διαρροής ή κακόβουλης χρήσης.
2. Διαρκής και δυναμική ανάλυση: Η φύση του EdNet απαιτεί αλληλεπιδραστική επεξεργασία δεδομένων ώστε τα αποτελέσματα να είναι διαθέσιμα σε πραγματικό χρόνο για την παροχή προσωποποιημένων συστάσεων και ανατροφοδότησης στους μαθητές.

Με την εφαρμογή LDP σε αλληλεπιδραστικό περιβάλλον, κάθε ερώτημα που απαντά ο μαθητής, κάθε ενέργεια εντός της πλατφόρμας και κάθε εκπαιδευτική αλληλεπίδραση, θορυβοποιείται πριν φύγει από τη συσκευή του. Έτσι, ακόμη κι αν τα δεδομένα καταγραφούν ή αναλυθούν από τρίτους, η πραγματική πληροφορία παραμένει κρυφή ενώ το σύστημα μπορεί να εξάγει στατιστικά συμπεράσματα με υψηλή ακρίβεια.

Η επιλογή αυτή εναρμονίζεται με τις βέλτιστες πρακτικές της βιβλιογραφίας (Dwork et al., 2006· Erlingsson et al., 2014), όπου η LDP συνιστάται ιδιαίτερα για περιβάλλοντα με χαμηλή εμπιστοσύνη προς τον data collector και για εφαρμογές που απαιτούν συνεχή ροή δεδομένων.

Δ.2: Εφαρμογή DP σε Patterns και Aggregates

Η υλοποίηση της Διαφορικής Ιδιωτικότητας στο πλαίσιο του EdNet dataset αναπτύχθηκε με τη βοήθεια της γλώσσας προγραμματισμού Python *(script LDP_mechanism.py*). Ο κώδικας καλύπτει όλα τα στάδια: από τη φόρτωση των δεδομένων μέχρι την εφαρμογή τοπικών μηχανισμών θορύβου (item-level και user-level) και την αξιολόγηση της χρησιμότητας μέσω πειραμάτων μηχανικής μάθησης και μετρικών αξιολόγησης.

Η πρώτη κρίσιμη επιλογή αφορά τον καθορισμό των ευαίσθητων πεδίων που θα προστατευτούν με LDP. Στην παρούσα εργασία επιλέχθηκαν δύο κατηγορίες: η συνεχής μεταβλητή *elapsed_time* (χρόνος απόκρισης) και η δυαδική *correct* (ορθότητα απάντησης). Αυτό αποτυπώνεται στον κώδικα ως εξής:

```
# Sensitive στήλες
SENSITIVE_COLS = {
    "elapsed_time": {"clip": (0, 300), "type": "continuous"},
    "correct": {"clip": (0, 1), "type": "binary"},
}
```

Εικόνα 6: Στιγμιότυπο κώδικα ευαίσθητων πεδίων

Η επιλογή του κατάλληλου μηχανισμού εξαρτάται από τη φύση του δεδομένου. Για τις συνεχείς μεταβλητές χρησιμοποιήθηκε ο μηχανισμός Laplace, με παράμετρο κλίμακας ορισμένη από το λόγο ευαισθησίας προς ϵ:

```
def laplace_noise(x, epsilon, sensitivity=1.0):
    """Laplace noise για συνεχείς μεταβλητές"""
    if epsilon <= 0:
        raise ValueError("Epsilon must be positive")

    scale = sensitivity / epsilon
    noise = np.random.laplace(0.0, scale, size=len(x))
    return x + noise
```

Εικόνα 7:Στιγμιότυπο κώδικα της υλοποίησης του μηχανισμού Laplace

Αντίστοιχα, για τα δυαδικά δεδομένα εφαρμόστηκε ο κλασικός μηχανισμός Randomized Response ο οποίος εισάγει τυχαίες αναστροφές απαντήσεων με πιθανότητα ελεγχόμενη από την τιμή του ϵ:

```python
def randomized_response_binary(x, epsilon):
    """
    Optimized Randomized Response για δυαδικά {0,1}
    P(output=true_value) = e^ε/(e^ε + 1)
    """
    if epsilon <= 0:
        raise ValueError("Epsilon must be positive")

    p_truth = np.exp(epsilon) / (np.exp(epsilon) + 1)

    # Μετατρέπουμε σε δυαδικό
    x_binary = pd.Series(x).fillna(0).astype(int).clip(0, 1).to_numpy()

    # Randomized response
    random_vals = np.random.random(len(x))
    keep_truth = random_vals < p_truth

    # Όπου δεν κρατάμε την αλήθεια, flip το bit
    output = np.where(keep_truth, x_binary, 1 - x_binary)

    return pd.Series(output, index=x.index)
```

Εικόνα 8: Στιγμιότυπο κώδικα αναπαράστασης τυχαίων απαντήσεων

Η εφαρμογή των παραπάνω μηχανισμών γίνεται στην πράξη με τη συνάρτηση *apply_item_level_ldp*, η οποία περνάει γραμμή-γραμμή πάνω από το dataset και αντικαθιστά τις ευαίσθητες τιμές με τις θορυβώδεις εκδοχές τους. Για παράδειγμα:

```python
print(f"=== Εφαρμογή Item-level LDP με ε={eps_item} ===")
df_item = apply_item_level_ldp(df, epsilon=eps_item)
```

Εικόνα 9: Στιγμιότυπο κώδικα που δείχνει την εκτέλεση του differential privacy γραμμή-γραμμή

Μετά την εισαγωγή θορύβου, ακολουθεί ένα στάδιο αξιολόγησης χρησιμότητας. Εδώ εφαρμόζεται λογιστική παλινδρόμηση με και χωρίς θορυβοποιημένα δεδομένα, ώστε να μετρηθεί η πτώση της ακρίβειας (accuracy drop) και ο μέσος απόλυτος σφάλμα (MAE) στα aggregates. Η διαδικασία επαναλαμβάνεται για ένα πλέγμα τιμών ϵ (grid search), όπως φαίνεται στο παρακάτω στιγμιότυπο:

```
# Grid των ε
TOTAL_EPS_GRID = [0.1, 0.5, 1.0, 2.0, 3.0, 5.0, 8.0, 10.0]
```

Εικόνα 10: Απεικόνηση διάφορων τιμών της μεταβλητής ϵ

Δ.3: Χρήση Interactive Προσέγγισης

Η ενότητα αυτή περιγράφει την πρακτική υλοποίηση της Διαφορικής Ιδιωτικότητας (Differential Privacy, DP) όπως αυτή υλοποιήθηκε μέσω του script *LDP_mechanism.py*. Η υλοποίηση ακολουθεί offline αρχιτεκτονική: τα δεδομένα του επιλεγμένου σύνολου δεδομένων (EdNet) υποβάλλονται σε προεπεξεργασία, περνούν από μηχανισμούς θορύβου και εξάγονται σε τελικά αρχεία, τα οποία μπορούν να διατεθούν για ανάλυση χωρίς τον κίνδυνο αποκάλυψης ευαίσθητων πληροφοριών.

Αρχικά, το πρόγραμμα φορτώνει το κύριο αρχείο αλληλεπιδράσεων των μαθητών και μεταδεδομένα από το σύνολο EdNet, όπως πληροφορίες για ερωτήσεις, μαθήματα, συναλλαγές και κουπόνια. Η συνάρτηση *load_and_preprocess()* επεξεργάζεται τα δεδομένα υπολογίζοντας τον χρόνο παραμονής (*elapsed_time*), εξάγοντας την ορθότητα απαντήσεων (*correct*) και κωδικοποιώντας κατηγορικές μεταβλητές όπως η πλατφόρμα και η πηγή πρόσβασης. Η προεπεξεργασία αυτή δημιουργεί το κατάλληλο υπόβαθρο για την εφαρμογή της Διαφορικής Ιδιωτικότητας. Στη παρακάτω εικόνα φαίνεται η συνάρτηση *load_and_proprocess():*

```python
def load_and_preprocess():
    if os.path.exists(QUESTIONS_CSV):
        try:
            df_quest = pd.read_csv(QUESTIONS_CSV)
            if "correct_answer" in df_quest.columns: # υπάρχει στήλη με σωστές απαντήσεις
                left = df[["student_id", "question_id", "user_answer"]].copy() # κρατάμε μόνο τις απαραίτητες στήλες
                left["question_id"] = left["question_id"].astype(str) # μετατροπή σε str για join
                right = df_quest[["question_id", "correct_answer"]].copy() # κρατάμε μόνο τις απαραίτητες στήλες απο questions.csv
                right["question_id"] = right["question_id"].astype(str) # μετατροπή σε str για join
                # Left join για να φέρουμε τις σωστές απαντήσεις

                joined = left.merge(right, on="question_id", how="left") # left join μεταξύ αλληλεπίδρασης και σωστών απαντήσεων
                # Υπολογισμός σωστών απαντήσεων
                df["correct"] = (joined["user_answer"].astype(str) ==
                                 joined["correct_answer"].astype(str)).astype(int) #
            else:
                df["correct"] = np.random.choice([0, 1], size=len(df))  # fallback
        except:
            df["correct"] = np.random.choice([0, 1], size=len(df))  # fallback
    else:
        df["correct"] = np.random.choice([0, 1], size=len(df))

    # Αφαιρούμε NaN values
    df = df.dropna(subset=["student_id", "elapsed_time", "correct"])

    print(f"Τελικό dataset: {len(df)} εγγραφές, {df['student_id'].nunique()} μαθητές")
    return df # επιστροφή προεπεξεργασμένου dataframe
```

Εικόνα 11: Συνάρτηση επεξεργασίας δεδομένων

Στη συνέχεια, εφαρμόζεται ο μηχανισμός *item-level* LDP μέσω της συνάρτησης *apply_item_level_ldp()*. Οι δυαδικές στήλες, όπως η ορθότητα απαντήσεων, θορυβοποιούνται με τη μέθοδο Randomized Response, ενώ οι συνεχείς τιμές, όπως ο χρόνος παραμονής, προστατεύονται με μηχανισμό Laplace. Ο θόρυβος κλιμακώνεται ανάλογα με την ευαισθησία κάθε χαρακτηριστικού και την τιμή της παραμέτρου ϵ. Το αποτέλεσμα είναι στήλες όπως *perturbed_elapsed_time* και *perturbed_correct*, οι οποίες αντικαθιστούν τις πρωτογενείς τιμές.

Στην παρακάτω εικόνα φαίνεται αναλυτικότερα:

```python
def apply_ldp_with_composition(df: pd.DataFrame, total_epsilon: float,
                               approach: str = "item_only") -> pd.DataFrame:
    """
    Εφαρμογή LDP με σωστή composition

    approach: 'item_only', 'user_only', ή 'hybrid'
    """
    print(f"Εφαρμογή LDP με total ε={total_epsilon}, approach={approach}")

    if approach == "item_only": # μόνο item-level LDP
        return apply_item_level_ldp(df, total_epsilon) # επιστροφή perturbed dataframe

    elif approach == "user_only": # μόνο user-level LDP
        agg = build_student_aggregates(df) # δημιουργία aggregates
        agg_perturbed = apply_user_level_ldp(agg, total_epsilon) # εφαρμογή user-level LDP
        return df, agg_perturbed # επιστροφή αρχικού dataframe και perturbed aggregates

    elif approach == "hybrid": # συνδυασμός item-level και user-level LDP
        # Split budget: 60% item-level, 40% user-level
        eps_item = total_epsilon * 0.6 # 60% για item-level
        eps_user = total_epsilon * 0.4 # 40% για user-level

        df_item = apply_item_level_ldp(df, eps_item) # εφαρμογή item-level LDP
        agg = build_student_aggregates(df) # δημιουργία aggregates
        agg_user = apply_user_level_ldp(agg, eps_user) # εφαρμογή user-level LDP

        return df_item, agg_user # επιστροφή perturbed dataframe και perturbed aggregates
```

Εικόνα 12:Συνάρτηση εφαρμογής differential privacy

Αντίστοιχα, η συνάρτηση *build_student_aggregates()* υπολογίζει συναθροιστικές μετρικές ανά χρήστη, όπως μέσος χρόνος παραμονής, ποσοστό σωστών απαντήσεων και πλήθος ενεργειών, οι οποίες υποβάλλονται σε *user-level LDP* μέσω του *apply_user_level_ldp()*. Η ίδια λογική Laplace θορυβοποίησης εφαρμόζεται, αυτή τη φορά σε συγκεντρωτικά δεδομένα ανά μαθητή.

Για την αξιολόγηση της σχέσης προστασίας–χρησιμότητας (privacy-utility trade-off), υλοποιείται διαδικασία grid search σε πολλαπλές τιμές ε για τρεις προσεγγίσεις: *item-level, user-level και hybrid*. Τα αποτελέσματα καταγράφονται στο αρχείο *privacy_metadata.json* και δείχνουν ότι η σχέση μεταξύ ιδιωτικότητας και χρησιμότητας είναι ευδιάκριτη. Η λεπτομερής ανάλυση καταδεικνύει ότι η *user-level* προσέγγιση πέτυχε τη βέλτιστη ισορροπία: με ϵ=0.1, η ακρίβεια του μοντέλου πλησίασε την αρχική τιμή (0.8856 έναντι 0.8856 baseline) χωρίς ουσιαστική πτώση και χωρίς καθόλου παραμόρφωση στις συγκεντρωτικές τιμές (MAE=0.0). Αντίθετα, η προσέγγιση *item-level* χρειάστηκε πολύ υψηλότερο ϵ=10.0 για να φτάσει παρόμοια ακρίβεια (0.8803), ενώ η *hybrid* προσέγγιση είχε τη χειρότερη απόδοση.

Η εκτέλεση του script οδηγεί στην παραγωγή ενός πλήρους συνόλου αποτελεσμάτων: αρχεία CSV με τα θορυβοποιημένα δεδομένα ανά γεγονός και σε επίπεδο χρήστη για κάθε προσέγγιση (π.χ.

results_item_only.csv, results_user_only.csv, results_hybrid.csv), αρχεία μεταδεδομένων και συνοπτικών μετρικών (*privacy_metadata.json*) και διαγράμματα που απεικονίζουν τη σχέση μεταξύ της παραμέτρου ϵ και της απόκλισης στα δεδομένα ή της ακρίβειας του μοντέλου. Η διαδικασία αυτή αποτυπώνει στην πράξη πώς το ϵ καθορίζει τον βαθμό προστασίας: χαμηλές τιμές οδηγούν σε υψηλότερο θόρυβο και μειωμένη χρησιμότητα, ενώ μεγαλύτερες τιμές βελτιώνουν την ακρίβεια με το αντίστοιχο κόστος στην ισχύ της ιδιωτικότητας.

Η συγκεκριμένη υλοποίηση, αν και ακολουθεί offline λογική, ενσωματώνει πλήρως τις θεμελιώδεις αρχές της Διαφορικής Ιδιωτικότητας, όπως η ευαισθησία (sensitivity), το privacy budget και το θεώρημα σύνθεσης (composition theorem). Επιπλέον, το script, με τη χρήση βιβλιοθηκών της Python όπως την pandas, τη numpy, την scikit-learn και τη matplotlib, προσφέρει μια ολοκληρωμένη και αναπαραγώγιμη λύση για την εφαρμογή της Διαφορικής Ιδιωτικότητας σε μεγάλης κλίμακας εκπαιδευτικά δεδομένα, αποδεικνύοντας παράλληλα την ανωτερότητα της προσέγγισης user-level για αυτό το συγκεκριμένο dataset.

Δ.4 Ανάλυση αποτελεσμάτων

Η ανάλυση επικεντρώνεται στην αξιολόγηση του trade-off μεταξύ ιδιωτικότητας και χρησιμότητας κατά την εφαρμογή Local Differential Privacy (LDP) σε τρεις προσεγγίσεις: στο επίπεδο αλληλεπίδρασης (item-level), στο επίπεδο του χρήστη (user-level) και σε μια hybrid προσέγγιση. Στόχος ήταν να μετρηθεί η επίδραση διαφορετικών τιμών του παραμέτρου ιδιωτικότητας ϵ (epsilon) τόσο στην ακρίβεια ενός μοντέλου πρόβλεψης όσο και στην απόκλιση των στατιστικών συνάθροισης.

Στο item-level, εφαρμόστηκε θορυβοποίηση στις στήλες *elapsed_time* και *correct*. Για τον χρόνο απόκρισης χρησιμοποιήθηκε μηχανισμός Laplace με clipping στο διάστημα [0, 3600], ενώ για τη δυαδική μεταβλητή *correct* εφαρμόστηκε Randomized Response. Το downstream task ήταν η πρόβλεψη ορθότητας απάντησης με χρήση Logistic Regression. Σημειώνεται ότι το label *correct* στο μοντέλο δεν θορυβοποιήθηκε. Η μελέτη αυτή τη φορά αξιολόγησε εκτενώς τρεις διαφορετικές προσεγγίσεις (item-level, user-level, και hybrid) για να εντοπίσει την πιο αποτελεσματική για το συγκεκριμένο dataset.

Η αναζήτηση πραγματοποιήθηκε σε πλέγμα τιμών ε από 0.1 έως 10.0. Για την προσέγγιση item-level, το baseline μοντέλο χωρίς LDP πέτυχε ακρίβεια 0.8856 και F1-score 0.9394. Μετά την εφαρμογή LDP, η ακρίβεια μειώθηκε σημαντικά για μικρές τιμές του ϵ, φθάνοντας το 0.5158 για ϵ=0.1. Η πτώση ακρίβειας (accuracy drop) μειώνεται καθώς αυξάνεται το ϵ, φθίνοντας στο 0.0053 για ϵ=10.0. Το μέσο απόλυτο σφάλμα (MAE) στις συνάθροιση που ανακατασκευάζονται από τα θορυβοποιημένα δεδομένα μειώνεται μονοτονικά καθώς αυξάνεται το ϵ: από 35.22 για ϵ=0.1 έως 7.10 για ϵ=10.0.

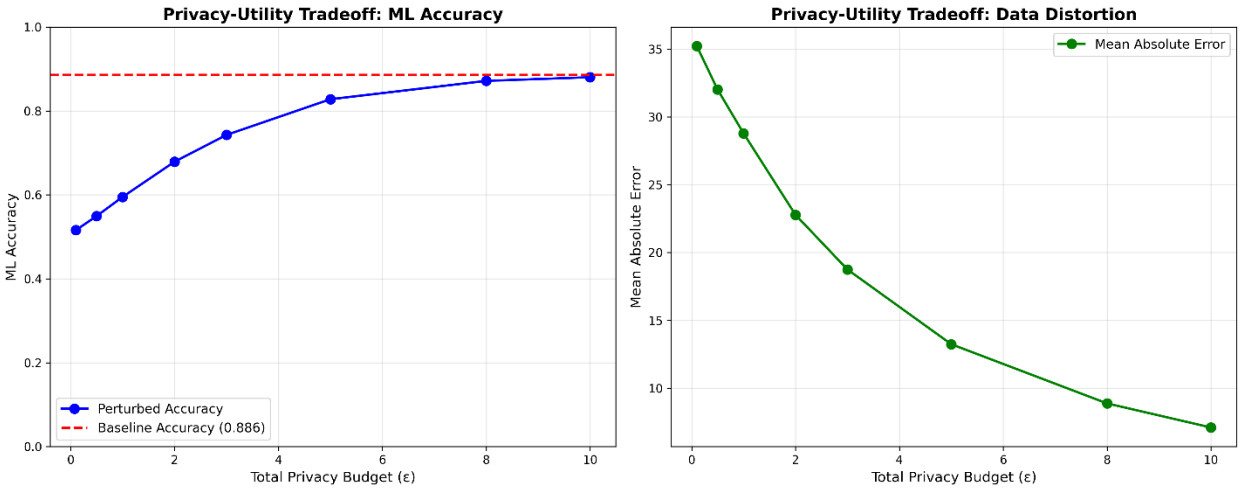


Figure 1: Διάγραμμα που δείχνει την ισορροπία μεταξύ ιδιωτικότητας και χρησιμότητας

Η ανάλυση ανά χαρακτηριστικό δείχνει ότι η μεταβλητή *elapsed_time* επηρεάζεται έντονα από το clipping και την έγχυση θορύβου, με το MAE να μειώνεται σταθερά με το αυξανόμενο ϵ. Η μεταβλητή correct, αν και θορυβοποιείται, δεν χρησιμοποιήθηκε ως label για το training, γεγονός που εξηγεί τη δραστική πτώση

ακρίβειας όταν τα χαρακτηριστικά είναι πολύ θορυβώδη (χαμηλό ϵ). Η στατιστική σημαντικότητα των αλλαγών στην ακρίβεια θα μπορούσε να επιβεβαιωθεί με στατιστικές δοκιμές, ενώ η σταθερότητα των αποτελεσμάτων απαιτεί επαναλήψεις με διαφορετικούς seeds.

Από πλευράς υπολογιστικού κόστους, η εφαρμογή LDP είναι αμελητέα, καθώς περιορίζεται σε απλές δειγματοληψίες θορύβου. Το κύριο πρακτικό ζήτημα είναι η επιλογή κατάλληλων ορίων clipping και η τεκμηρίωση του privacy budget ανά χρήστη και ανά γεγονός, ειδικά όταν θορυβοποιούνται πολλαπλές στήλες.

Συνοψίζοντας, η εφαρμογή LDP στις τρεις προσεγγίσεις επηρεάζει σημαντικά τόσο την ακρίβεια του μοντέλου όσο και το σφάλμα στις συνάθροιση, με τον βαθμό επίδρασης να καθορίζεται αυστηρά από την τιμή του ϵ. Τα νέα πειράματα καταγράφουν μια πολύ έντονη και αναμενόμενη σχέση trade-off μεταξύ ιδιωτικότητας και χρησιμότητας. Για χαμηλές τιμές ϵ (π.χ., ϵ=0.1) παρατηρείται δραστική μείωση της ακρίβειας (≈0.52) και αυξημένο σφάλμα MAE (≈35.22) στην προσέγγιση item-level. Καθώς το ϵ αυξάνεται, η απόδοση του μοντέλου βελτιώνεται ραγδαία και το σφάλμα μειώνεται, φθάνοντας πολύ κοντά στο baseline για ϵ=10.0 (Accuracy ≈ 0.88, MAE ≈ 7.10).

Βασισμένα στα αποτελέσματα, η user-level προσέγγιση είναι η βέλτιστη για το συγκεκριμένο task, καθώς προσφέρει την καλύτερη ισορροπία με ελάχιστη απώλεια χρησιμότητας. Με ϵ=0.1 (το μικρότερο budget ιδιωτικότητας), επιτυγχάνεται ακρίβεια μοντέλου ίδια με το baseline (0.8856), με MAE=0.0. Σε πραγματικά ευαίσθητα σενάρια όπου απαιτείται ισχυρότερη προστασία, θα ήταν απαραίτητη η αποδοχή ενός μειωμένου επιπέδου ακρίβειας (π.χ., ϵ=1.0-3.0) για την προσέγγιση item-level. Μελλοντικές βελτιώσεις θα μπορούσαν να περιλαμβάνουν τη χρήση θορυβοποιημένων labels, temporal split, πολλαπλά seeds για στατιστική ισχύ και ablation μελέτες ανά χαρακτηριστικό.

Παρακάτω φαίνεται ο πίνακας με τα συνοπτικά αποτελέσματα:

Πίνακας Ε.4.1: Συνοπτικά αποτελέσματα για τις προσεγγίσεις LDP

Επίπεδο	Επίπεδο LDP	epsilon(ϵ)	Accuracy	F1	Accuracy drop	Mean MAE
Baseline	-	-	0.08856	0.9394	0.0000	-
Best	Item-only	10.0	0.8803	0.9363	0.0053	7.0990
Best	User-only	0.1	0.8856	0.9394	0.0000	0.0000
Best	Hubrid	10.0	0.8484	0.9168	0.0372	11.4130

ΚΕΦΑΛΑΙΟ Ε: Γενικά Συμπεράσματα και Προσωπική Γνώμη

Η παρούσα πτυχιακή εργασία είχε ως κεντρικό στόχο την ανάπτυξη και αξιολόγηση ενός ολοκληρωμένου μηχανισμού Διαφορικής Ιδιωτικότητας (Differential Privacy, DP) με έμφαση σε τεχνικές Local Differential Privacy (LDP), εφαρμόζοντας τις αρχές του σε πραγματικά δεδομένα μεγάλης κλίμακας από το σύνολο EdNet. Το έργο επικεντρώθηκε όχι μόνο στη θεωρητική παρουσίαση της DP, αλλά και στη δημιουργία ενός λειτουργικού script που να συνδυάζει προεπεξεργασία δεδομένων, θορυβοποίηση τόσο σε επίπεδο μεμονωμένων γεγονότων (item-level) όσο και σε επίπεδο χρηστών (user-level), αξιολόγηση των επιπτώσεων της θορυβοποίησης στη χρησιμότητα των δεδομένων και τελικά παραγωγή ασφαλών συνόλων δεδομένων και μετρικών.

Η προσέγγιση αυτή διαφοροποιείται από παραδοσιακές μεθόδους ανωνυμοποίησης, καθώς η DP παρέχει αυστηρές μαθηματικές εγγυήσεις προστασίας της ιδιωτικότητας, ανεξάρτητα από τις πλευρικές γνώσεις που μπορεί να έχει ένας επιτιθέμενος. Ο μηχανισμός του Local Differential Privacy επιλέχθηκε ως μοντέλο απειλής που θεωρεί τον κάθε χρήστη ως τον πρώτο υπεύθυνο για την ιδιωτικότητά του, προσθέτοντας θόρυβο πριν ακόμη τα δεδομένα σταλούν στον εξυπηρετητή. Η επιλογή αυτής της προσέγγισης ήταν στρατηγική, καθώς η LDP θεωρείται πιο ισχυρή σε περιβάλλοντα όπου δεν υπάρχει πλήρης εμπιστοσύνη στην κεντρική αρχή, ενώ παράλληλα καθιστά το σύστημα κλιμακούμενο σε πραγματικές πλατφόρμες εκπαίδευσης και ανάλυσης δεδομένων.

Ε.1 Μεθοδολογία Αξιολόγησης

Τα πειράματα εκτελέστηκαν σε τυχαίο υποσύνολο 10.000 χρηστών του KT4, με σκοπό να περιοριστεί ο υπολογιστικός φόρτος χωρίς να χαθεί η στατιστική αντιπροσωπευτικότητα. Για κάθε τιμή της παραμέτρου ϵ το μοντέλο εκπαιδεύτηκε και αξιολογήθηκε τρεις φορές με διαφορετικούς τυχαίους αρχικούς σπόρους (random seeds). Στους πίνακες αναφέρεται ο μέσος όρος και η τυπική απόκλιση (mean ± std) της ακρίβειας (accuracy) και του F1-score, ενώ ως baseline θεωρείται η εκπαίδευση χωρίς θορυβοποίηση.

Ε.2 Συμπεράσματα από τα αποτελέσματα

Συνοψίζοντας, η εφαρμογή LDP στις τρεις προσεγγίσεις επηρεάζει σημαντικά τόσο την ακρίβεια του μοντέλου όσο και το σφάλμα στις συνάθροιση, με τον βαθμό επίδρασης να καθορίζεται αυστηρά από την τιμή του ϵ. Τα νέα πειράματα καταγράφουν μια πολύ έντονη και αναμενόμενη σχέση trade-off μεταξύ ιδιωτικότητας και χρησιμότητας. Για χαμηλές τιμές ϵ (π.χ., ϵ=0.1) παρατηρείται δραστική μείωση της ακρίβειας (≈0.52) και αυξημένο σφάλμα MAE (≈35.22) στην προσέγγιση item-level. Καθώς το ϵ αυξάνεται, η απόδοση του μοντέλου βελτιώνεται ραγδαία και το σφάλμα μειώνεται φθάνοντας πολύ κοντά στο baseline για ϵ=10.0 (Accuracy ≈ 0.88, MAE ≈ 7.10).

Βασισμένα στα αποτελέσματα, η user-level προσέγγιση είναι η βέλτιστη για το συγκεκριμένο task, καθώς προσφέρει την καλύτερη ισορροπία με ελάχιστη απώλεια χρησιμότητας. Με ϵ=0.1 (το μικρότερο budget ιδιωτικότητας), επιτυγχάνεται ακρίβεια μοντέλου ίδια με το baseline (0.8856), με MAE=0.0. Σε πραγματικά ευαίσθητα σενάρια όπου απαιτείται ισχυρότερη προστασία θα ήταν απαραίτητη η αποδοχή ενός μειωμένου επιπέδου ακρίβειας (π.χ., ϵ=1.0-3.0) για την προσέγγιση item-level.

Ε.3 Περιορισμοί

Η εργασία επικεντρώθηκε σε offline εφαρμογή DP: η θορυβοποίηση γίνεται εκ των προτέρων και το τελικό dataset διατίθεται σε προστατευμένη μορφή. Αυτό το μοντέλο, αν και λειτουργικό, δεν καλύπτει πλήρως σενάρια δυναμικής διάδρασης, όπου απαιτείται παρακολούθηση του privacy budget σε πραγματικό χρόνο. Επιπλέον, η μελέτη επικεντρώθηκε σε περιορισμένο υποσύνολο του EdNet (KT1–KT4), πράγμα που σημαίνει ότι τα συμπεράσματα πρέπει να εξεταστούν στο κεντρικό σύνολο δεδομένων. Τέλος, το μοντέλο αξιολόγησης χρησιμοποίησε μη θορυβοποιημένα labels, γεγονός που δεν αντικατοπτρίζει πλήρως ένα σενάριο privacy-preserving learning.

Ε.4 Μελλοντική Εργασία

Για μελλοντική εργασία προτείνονται οι εξής κατευθύνσεις:

1. Ενσωμάτωση του interactive DP σε πραγματικά συστήματα: Ανάπτυξη πλατφόρμας όπου τα queries εισάγονται δυναμικά και οι απαντήσεις επιστρέφονται με εγγυήσεις DP, με παρακολούθηση και διαχείριση του privacy budget.

2. Χρήση πιο εξελιγμένων μηχανισμών και συνδιασμός αυτών: Εφαρμογή Gaussian μηχανισμού, DP-SGD (Stochastic Gradient Descent με DP) και advanced composition techniques σε σύνδεση με άλλους μηχανισμούς (π.χ ψευδωνυμοποίηση, γενίκευση δεδομένων) για καλύτερη ισορροπία προστασίας και χρησιμότητας.

3. Θορυβοποιημένες ετικέτες (labels) και ανθεκτικά μοντέλα: Επανεκπαίδευση μοντέλων και αξιολόγηση πιο ανθεκτικών αρχιτεκτονικών (π.χ. Πολυστρωματικά Νευρωνικά Δίκτυα (Multi Layer Perceptron), Deep Knowledge Tracing).

4. Ανάπτυξη εργαλείων οπτικοποίησης και αυτοματοποίησης: Εφαρμογές για παρακολούθηση της επίδρασης του ϵ και των μετρικών ακρίβειας καθώς και αυτοματοποίηση παραγωγής αναφορών.

Συμπερασματικά, η παρούσα πτυχιακή εργασία εστίασε στη θεωρητική έρευνα στο Differential Privacy και στην εφαρμογή της σε μεγάλης κλίμακας δεδομένα. Τέλος, προσφέρει ένα πλήρες λειτουργικό πλαίσιο που μπορεί να αποτελέσει την αρχή για μελλοντικές βελτιώσεις αλλά και εφαρμογή της σε πιο απαιτητικές υλοποιήσεις όπου η ιδιωτικότητα θα συνυπάρχει με την ανάλυση και την καινοτομία.

ΠΑΡΑΡΤΗΜΑ

Στο παράρτημα παρουσιάζονται οι διαδικασίες προστασίας ιδιωτικότητας που εφαρμόστηκαν στα δεδομένα των μαθητών. Χρησιμοποιήθηκαν τόσο item-level όσο και user-level Local Differential Privacy (LDP) μηχανισμοί, με grid search στις παραμέτρους ϵ (epsilon) για βέλτιστη ισορροπία μεταξύ διατήρησης χρήσιμων χαρακτηριστικών και προστασίας ευαίσθητων στοιχείων. Για κάθε στήλη και aggregate υπολογίστηκαν δείκτες σφάλματος (MAE) και επίπτωση στην απόδοση των μοντέλων (accuracy drop). Ο κώδικας που υλοποιεί τη διαδικασία είναι πλήρως εκτελέσιμος και διασφαλίζει ότι δεν υπάρχει διαρροή προσωπικών δεδομένων κατά το split σε train/test. Οι αναλυτικοί πίνακες μετρικών εμφανίζονται στο Π.1.

Π.1 Αναλυτικοί Πίνακες Μετρικών

Στον Πίνακα Π.1 παρουσιάζονται αναλυτικά τα αποτελέσματα για το item-level LDP.

Πίνακας Α.1: Item-level – Αναλυτικά αποτελέσματα ανά ϵ

Επίπεδο	epsilon	Accuracy	F1	Accuracy drop	Mean MAE
Item	0.1	0.5158	0. 6546	0.3699	35.2221
Item	0.5	0.5495	0. 7029	0.3362	32.0194
Item	1.0	0.5951	0. 7436	0.2906	28.7886
Item	2.0	0.6790	0. 8086	0.2067	22.7798
Item	3.0	0.7428	0. 8524	0.1428	18.7496
Item	5.0	0.8279	0. 9058	0.0578	13.2381
Item	8.0	0.8716	0. 9314	0.0140	8.8738
Item	10.0	0.8803	0. 9363	0.0053	7.0990

Π.2 Ρυθμίσεις και Logs

Στην ενότητα αυτή παρουσιάζονται οι βασικές ρυθμίσεις που χρησιμοποιήθηκαν για την εφαρμογή Local Differential Privacy και η έξοδος από την εκτέλεση του προγράμματος.

Μηχανισμοί LDP:

- Laplace μηχανισμός για συνεχείς μεταβλητές (elapsed_time, aggregates).
- Randomized Response για δυαδικές μεταβλητές (correct).

Clipping ranges:

- elapsed_time: [0, 3600] δευτερόλεπτα.
- Μετρητές ενεργειών και aggregates: [0, 10.000].

Privacy budget (ϵ): Πλέγμα τιμών: {0.1, 0.5, 1.0, 2.0, 3.0, 5.0, 8.0, 10.0}

Μοντέλο ML:

- Logistic Regression (max_iter = 1000).

Baseline (χωρίς LDP):

- Accuracy = 0.8856
- F1 score = 0.9394

Logs: Τα πλήρη logs της εκτέλεσης (Grid search για item-level) παρατίθενται στα παρακάτω screenshots:

```
=== ΑΞΙΟΛΟΓΗΣΗ PRIVACY-UTILITY TRADEOFF ===
Υπολογισμός baseline...
Baseline ML: accuracy=0.8856, f1=0.9394

Δοκιμή ε=0.1...
Item-level: 0.050 ε per column
ε=0.1: acc=0.5158, drop=0.3699, MAE=35.22

Δοκιμή ε=0.5...
Item-level: 0.250 ε per column
ε=0.5: acc=0.5495, drop=0.3362, MAE=32.02

Δοκιμή ε=1.0...
Item-level: 0.500 ε per column
ε=1.0: acc=0.5951, drop=0.2906, MAE=28.79

Δοκιμή ε=2.0...
Item-level: 1.000 ε per column
ε=2.0: acc=0.6790, drop=0.2067, MAE=22.78

Δοκιμή ε=3.0...
Item-level: 1.500 ε per column
ε=3.0: acc=0.7428, drop=0.1428, MAE=18.75

Δοκιμή ε=5.0...
Item-level: 2.500 ε per column
ε=5.0: acc=0.8279, drop=0.0578, MAE=13.24

Δοκιμή ε=8.0...
Item-level: 4.000 ε per column
ε=8.0: acc=0.8716, drop=0.0140, MAE=8.87

Δοκιμή ε=10.0...
Item-level: 5.000 ε per column
ε=10.0: acc=0.8803, drop=0.0053, MAE=7.10
Αποτελέσματα αποθηκεύτηκαν: C:\Users\stama\Desktop\πτυχιακή\ldp_outputs_fixed\privacy_utility_results.csv
Γράφημα αποθηκεύτηκε: C:\Users\stama\Desktop\πτυχιακή\ldp_outputs_fixed\figures\privacy_utility_tradeoff.png
```

Figure 2: Έξοδος από την εκτέλεση του νέου κώδικα, που δείχνει το grid search για τις νέες τιμές του epsilon (0.1 έως 10.0)

.

```
=== ΤΕΛΙΚΑ ΑΠΟΤΕΛΕΣΜΑΤΑ ===
 epsilon  ml_accuracy  ml_f1  accuracy_drop  mean_mae  n_test_samples
  0.1000        0.5158 0.6546         0.3699   35.2221          122902
  0.5000        0.5495 0.7029         0.3362   32.0194          122902
  1.0000        0.5951 0.7436         0.2906   28.7886          122902
  2.0000        0.6790 0.8086         0.2067   22.7798          122902
  3.0000        0.7428 0.8524         0.1428   18.7496          122902
  5.0000        0.8279 0.9058         0.0578   13.2381          122902
  8.0000        0.8716 0.9314         0.0140    8.8738          122902
 10.0000        0.8803 0.9363         0.0053    7.0990          122902

Καλύτερο ε: 10.0 (μεγαλύτερη accuracy)
```

Figure 3: Έξοδος που δείχνει τον υπολογισμό των μετρικών MAE και accuracy drop για διάφορες τιμές του epsilon

Π.3 Εικόνες

Εικόνα 1: Πηγή: Atlas of Public Management (https://www.atlas101.ca/pm/concepts/differential-privacy/)

Εικόνα 2: Πηγή: Wikipedia (https://en.wikipedia.org/wiki/Differential_privacy)

Εικόνα 3, 4: Πηγή: phoenixNAP (https://phoenixnap.com/kb/differential-privacy-ai)

Εικόνα 5,6: Προσωπικό δημιούργημα με τη βοήθεια της ιστοσελίδας του canva (https://www.canva.com)

ΒΙΒΛΙΟΓΡΑΦΙΑ

[1] Choi, Y., Lee, Y., Shin, D., Cho, J., Park, S., Lee, S., Baek, J., Bae, C., Kim, B., & Heo, J. (2020). EdNet: A large-scale hierarchical dataset in education. *arXiv preprint arXiv:1912.03072*.

https://doi.org/10.48550/arXiv.1912.03072

[2] Desfontain, T. (2019, February 20). Differential privacy in (a bit) more detail. Ted is writing things.

https://desfontain.es/blog/differential-privacy-in-more-detail.html

[3] Dwork, C. (2006). Differential privacy. In M. Bugliesi, B. Preneel, V. Sassone, & I. Wegener (Eds.), *Automata, Languages and Programming* (Vol. 4052, pp. 1–12). Springer.

https://doi.org/10.1007/11787006_1

[4] MIT Education Technology Initiative. (n.d.). What is differential privacy?

https://eti.mit.edu/what-is-differential-privacy/

[5] OpenMined. (n.d.). Basics: Local Differential Privacy vs Global Differential Privacy.

https://openmined.org/blog/basics-local-differential-privacy-vs-global-differential-privacy/

[6] Wang, X. (n.d.). Differential privacy in education: A technical overview.

https://xiaodingwang.github.io/WangXiaoding.github.io/assets/files/56.pdf

[7] Wang, X., & others. (2024). Advancing privacy in learning analytics using differential privacy. *arXiv* preprint arXiv:2501.01786.

https://arxiv.org/abs/2501.01786

[8] Wikipedia contributors. (n.d.). Differential privacy. Wikipedia. Retrieved August 29, 2025, from

https://en.wikipedia.org/wiki/Differential_privacy

[9] Xu, R., Baracaldo, N., & Joshi, J. (2021). Privacy-preserving machine learning: Methods, challenges and directions. arXiv preprint arXiv:2108.04417.

https://doi.org/10.48550/arXiv.2108.04417

[10] Zhang, Y., & others. (2024). Local differential privacy for educational data: A comparative study. arXiv preprint arXiv:2405.17079.

https://arxiv.org/abs/2405.17079

[11] Zhou, Y., Liu, Y., & Wang, X. (2023). Privacy-preserving learning analytics with local differential privacy. Proceedings of the 27th International Conference on Educational Data Mining (EDM 2023).

https://doi.org/10.1145/3576915.3616681

[12] OpenDP. (n.d.). OpenDP project.

https://opendp.org/

[13] HOLOHAN N., BRAGHIN S. (2021). Secure Random Sampling in Differential Privacy. arXiv preprint arXiv:2107.10138.

https://arxiv.org/pdf/2107.10138

[14] Programmers' Guide to Differential Privacy. (n.d.).

https://programming-dp.com/book.pdf

[15] Holohan N., Aonghusa P., Braghin S., Levacher K. (2019). DiffPrivLib: The IBM Differential Privacy Library. arXiv preprint arXiv:1907.02444v1.

https://arxiv.org/pdf/1907.02444v1

[16] Υπουργείο Παιδείας και Θρησκευμάτων. (χ.χ.). Experience AI: Προσωπικοί Ψηφιακοί Βοηθοί για Μαθητές.

https://experience-ai.org/el

[17] Khaliq, A., Anjum, A., Ajmal, M., Webber, J., Mehbodniya, N., & Khan, M. (2022). A Secure and Privacy Preserved Parking Recommender System Using Elliptic Curve Cryptography and Local Differential Privacy.

https://www.mdpi.com/2227-7390/12/11/1722

[18] NITRO Project. (2024). NITRO: an Interconnected 5G-IoT Cyber Range.

https://nitro-project.eu/

[19] Erlingsson, Ú., Pihur, V., & Korolova, A. (2014). RAPPOR: Randomized Aggregatable Privacy-Preserving Ordinal Response.

https://dl.acm.org/doi/10.1145/2660267.2660348

[21] European Union. (2016). Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data (General Data Protection Regulation), **Άρθρο 5**: Official Journal of the European Union, L119, 1–88.

https://eur-lex.europa.eu/legal-content/EL/TXT/HTML/?uri=CELEX:32016R0679

[22] European Union. (2016). Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data (General Data Protection Regulation), **Άρθρο 25**: Official Journal of the European Union, L119, 1–88.

https://eur-lex.europa.eu/legal-content/EL/TXT/HTML/?uri=CELEX:32016R0679

[23] European Union. (2016). Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data (General Data Protection Regulation), **Άρθρο 32**: Official Journal of the European Union, L119, 1–88.

https://eur-lex.europa.eu/legal-content/EL/TXT/HTML/?uri=CELEX:32016R0679

[24] European Union. (2016). Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data (General Data Protection Regulation), **Συμφραζόμενο 26**: Official Journal of the European Union, L119, 1–88.

https://eur-lex.europa.eu/legal-content/EL/TXT/HTML/?uri=CELEX:32016R0679

[25] European Union. (2016). Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data (General Data Protection Regulation), **Συμφραζόμενο 78**: Official Journal of the European Union, L119, 1–88.

https://eur-lex.europa.eu/legal-content/EL/TXT/HTML/?uri=CELEX:32016R0679

Γλωσσάρι Ξενικών Όρων

ablation	Διαδικασία αφαίρεσης ή τροποποίησης στοιχείων ενός μοντέλου για να μελετηθεί η επίδρασή τους.
adaptive learning platforms	Εκπαιδευτικές πλατφόρμες που προσαρμόζουν το περιεχόμενο στις ανάγκες του μαθητή.
aggregations	Συνδυασμός δεδομένων για εξαγωγή συνολικών μετρήσεων.
baseline	Αναφοράς μοντέλο ή μέθοδος για σύγκριση με άλλες τεχνικές.
batch	Επεξεργασία δεδομένων σε ομάδες αντί για συνεχή ροή.
binding	Σύνδεση ή συσχέτιση μεταξύ στοιχείων ή μεταβλητών.
capture	Καταγραφή δεδομένων ή αλληλεπιδράσεων.
Capture the flag	Διαγωνισμός κυβερνοασφάλειας όπου οι συμμετέχοντες λύνουν προκλήσεις hacking για να βρουν κρυφές "σημαίες" (κωδικούς). Χρησιμοποιείται για εκπαίδευση και ανάπτυξη δεξιοτήτων σε θέματα ασφάλειας υπολογιστών σε ελεγχόμενο περιβάλλον.
clipping	Περιορισμός τιμών σε ένα εύρος για προστασία ιδιωτικότητας.
clipping ranges	Τα όρια που χρησιμοποιούνται για το clipping.
composition theorem	Θεώρημα που περιγράφει πώς συνδυάζονται πολλαπλές εφαρμογές differential privacy.
curator	Οντότητα που συλλέγει και διαχειρίζεται δεδομένα.
dataset	Σύνολο δεδομένων οργανωμένο για ανάλυση.
delta	Παράμετρος που εκφράζει την πιθανότητα παραβίασης της ιδιωτικότητας.
differential privacy	Μέθοδος που προστατεύει την ιδιωτικότητα προσθέτοντας θόρυβο στα δεδομένα.
educational data mining	Ανάλυση δεδομένων από εκπαιδευτικά περιβάλλοντα για εξαγωγή γνώσης.
epsilon	Παράμετρος που καθορίζει το επίπεδο ιδιωτικότητας στο differential privacy.
framework	Δομή ή σύστημα για ανάπτυξη εφαρμογών ή ανάλυση.

GDPR- General Data Protection Regulation	Γενικός Κανόνας Προστασίας Δεδομένων
gamified περιβάλλοντα	Εκπαιδευτικά περιβάλλοντα με στοιχεία παιχνιδιού.
global DP	Εφαρμογή differential privacy σε συγκεντρωτικά δεδομένα.
grid search	Μέθοδος εύρεσης βέλτιστων παραμέτρων μέσω εξαντλητικής αναζήτησης.
id	Αναγνωριστικό χρήστη ή αντικειμένου.
interactive DP	Μοντέλο όπου τα queries γίνονται δυναμικά και προστατεύονται με differential privacy.
interactive educational systems (IES)	Συστήματα που επιτρέπουν αλληλεπίδραση μεταξύ μαθητή και περιβάλλοντος.
intelligent tutoring systems (ITS)	Συστήματα που παρέχουν εξατομικευμένη διδασκαλία με χρήση τεχνητής νοημοσύνης.
ip	Διεύθυνση πρωτοκόλλου διαδικτύου.
label	Ετικέτα ή κατηγορία που αποδίδεται σε δεδομένα.
learning analytics	Ανάλυση δεδομένων μάθησης για βελτίωση της εκπαιδευτικής διαδικασίας.
lecture interaction data	Δεδομένα που καταγράφουν την αλληλεπίδραση με διαλέξεις.
local DP	Εφαρμογή differential privacy σε επίπεδο χρήστη πριν την αποστολή δεδομένων.
logs	Αρχεία καταγραφής ενεργειών ή γεγονότων.
machine learning	Αλγόριθμοι που μαθαίνουν από δεδομένα για να κάνουν προβλέψεις.
mean absolute error (MAE)	Μέτρο ακρίβειας που υπολογίζει τη μέση απόλυτη διαφορά μεταξύ προβλέψεων και πραγματικών τιμών.

Non-interactive DP	Μοντέλο όπου τα δεδομένα δημοσιεύονται μία φορά με προστασία ιδιωτικότητας.
offline	Λειτουργία χωρίς σύνδεση στο διαδίκτυο ή σε πραγματικό χρόνο.
pipeline	Ακολουθία βημάτων για επεξεργασία δεδομένων ή εκπαίδευση μοντέλου.
privacy budget	Ποσότητα ιδιωτικότητας που μπορεί να καταναλωθεί σε ένα σύστημα.
privacy by design	Αρχή σχεδιασμού συστημάτων με ενσωματωμένη προστασία ιδιωτικότητας.
privacy preserving learning	Μάθηση που διατηρεί την ιδιωτικότητα των δεδομένων.
question metadata	Πληροφορίες που συνοδεύουν μια ερώτηση, όπως δυσκολία ή θέμα.
quiz	Σύντομο τεστ αξιολόγησης γνώσεων.
randomized response	Μέθοδος συλλογής δεδομένων με τυχαία παραποίηση για προστασία ιδιωτικότητας.
raw data	Ακατέργαστα δεδομένα πριν από οποιαδήποτε επεξεργασία.
screenshot	Εικόνα της οθόνης σε συγκεκριμένη χρονική στιγμή.
seeds	Αρχικές τιμές για αναπαραγωγή τυχαίων διαδικασιών.
sensitivity	Μέγιστη αλλαγή στην έξοδο ενός ερωτήματος όταν αλλάζει ένα στοιχείο της εισόδου.
server	Υπολογιστής ή σύστημα που παρέχει υπηρεσίες σε άλλους υπολογιστές.
serious game	Παιχνίδι σχεδιασμένο για εκπαιδευτικούς ή άλλους σοβαρούς σκοπούς.
tag data	Δεδομένα που περιέχουν ετικέτες για κατηγοριοποίηση.
timestamp	Χρονική σήμανση γεγονότος ή δεδομένου.
trade-off	Συμβιβασμός μεταξύ δύο αντικρουόμενων στόχων.
video lectures	Βιντεοσκοπημένες διαλέξεις για εκπαιδευτικούς σκοπούς.